



ΠΑΝΕΠΙΣΤΗΜΙΟ
ΠΑΤΡΩΝ
UNIVERSITY OF PATRAS

ΤΜΗΜΑ ΜΗΧΑΝΙΚΩΝ ΗΛΕΚΤΡΟΝΙΚΩΝ ΥΠΟΛΟΓΙΣΤΩΝ ΚΑΙ ΠΛΗΡΟΦΟΡΙΚΗΣ
ΠΟΛΥΤΕΧΝΙΚΗ ΣΧΟΛΗ

Πρόβλεψη Αποτελεσμάτων Ποδοσφαιρικών
αγώνων με χρήση εργαλείων αναλυτικής
δεδομένων μεγάλου όγκου

ΔΙΠΛΩΜΑΤΙΚΗ ΕΡΓΑΣΙΑ

του

ΧΡΗΣΤΟΥ ΨΑΘΟΓΙΑΝΝΑΚΗ

Επιβλέπων: Σπυρίδων Σιούτας
Καθηγητής
Συνεπιβλέπων: Χρήστος Μακρής
Αναπληρωτής Καθηγητής
Συνεπιβλέπων: Δημήτριος Τσώλης
Αναπληρωτής Καθηγητής

Πάτρα, Ιούλιος 2025



Πανεπιστήμιο Πατρών

Πολυτεχνική Σχολή

Τμήμα Μηχανικών Ηλεκτρονικών Υπολογιστών και Πληροφορικής

Πρόβλεψη Αποτελεσμάτων Ποδοσφαιρικών αγώνων με χρήση εργαλείων αναλυτικής δεδομένων μεγάλου όγκου

ΔΙΠΛΩΜΑΤΙΚΗ ΕΡΓΑΣΙΑ

του

ΧΡΗΣΤΟΥ ΨΑΘΟΓΙΑΝΝΑΚΗ

Επιβλέπων: Σπυρίδων Σιούτας

Καθηγητής

Συνεπιβλέπων: Χρήστος Μακρής

Αναπληρωτής Καθηγητής

Συνεπιβλέπων: Δημήτριος Τσώλης

Αναπληρωτής Καθηγητής

Εγκρίθηκε από την διμελή εξεταστική επιτροπή την 3/7/2025.

(Υπογραφή)

(Υπογραφή)

.....

Σπυρίδων Σιούτας

Καθηγητής

.....

Ονοματεπώνυμο

Τίτλος

Πάτρα, Ιούλιος 2025



Πανεπιστήμιο Πατρών
Πολυτεχνική Σχολή
Τμήμα Μηχανικών Ηλεκτρονικών Υπολογιστών και Πληροφορικής

Copyright ©–All rights reserved Χρήστος Ψαθογιαννάκης, 2025.

Με την επιφύλαξη παντός δικαιώματος.

Απαγορεύεται η αντιγραφή, αποθήκευση και διανομή της παρούσας εργασίας, εξ ολοκλήρου ή τμήματος αυτής, για εμπορικό σκοπό. Επιτρέπεται η ανατύπωση, αποθήκευση και διανομή για σκοπό μη κερδοσκοπικό, εκπαιδευτικής ή ερευνητικής φύσης, υπό την προϋπόθεση να αναφέρεται η πηγή προέλευσης και να διατηρείται το παρόν μήνυμα.

Το περιεχόμενο αυτής της εργασίας δεν απηχεί απαραίτητα τις απόψεις του Τμήματος, του Επιβλέποντα, ή της επιτροπής που την ενέκρινε.

Υπεύθυνη Δήλωση

Βεβαιώνω ότι είμαι συγγραφέας αυτής της διπλωματικής εργασίας, και ότι κάθε βοήθεια την οποία είχα για την προετοιμασία της είναι πλήρως αναγνωρισμένη και αναφέρεται στην διπλωματική εργασία. Επίσης έχω αναφέρει τις όποιες πηγές από τις οποίες έκανα χρήση δεδομένων, ιδεών ή λέξεων, είτε αυτές αναφέρονται ακριβώς είτε παραφρασμένες. Επίσης, βεβαιώνω ότι αυτή η διπλωματική εργασία προετοιμάστηκε από εμένα προσωπικά ειδικά για τις απαιτήσεις του προγράμματος σπουδών του Τμήματος Μηχανικών Ηλεκτρονικών Υπολογιστών και Πληροφορικής του Πανεπιστημίου Πατρών.

(Υπογραφή)

.....

Χρήστος Ψαθογιαννάκης

Ευχαριστίες

Θα ήθελα να ευχαριστήσω τους φίλους μου και την οικογένεια μου για την στήριξη σε όλη την διάρκεια των σπουδών μου. Επίσης θα ήθελα να ευχαριστήσω τον καθηγητή Σπυρίδων Σιούτα που μου έδωσε την ευκαιρία να εκπονήσω την διπλωματική μου εργασία.

Περίληψη

Η συνεχής πρόοδος στην τεχνολογία των υπολογιστών και στην ανάλυση δεδομένων έχει επηρεάσει σημαντικά τον χώρο του αθλητισμού. Στο σύγχρονο ποδόσφαιρο, ιδιαίτερα σε επαγγελματικό επίπεδο, πολλές ομάδες διαθέτουν εξειδικευμένα τμήματα ανάλυσης δεδομένων με στόχο την ανάδειξη αδυναμιών και πλεονεκτημάτων, τόσο της δικής τους ομάδας όσο και των αντιπάλων. Παράλληλα, οι εταιρείες στοιχημάτων (bookmakers) χρησιμοποιούν παρόμοιες τεχνικές για να προβλέψουν τον πιθανότερο νικητή και να διαμορφώσουν τις αποδόσεις τους.

Στην παρούσα διπλωματική εργασία χρησιμοποιούνται δεδομένα από την Αγγλική Premier League για την περίοδο 2019–2024, με σκοπό την ανάλυση και πρόβλεψη των αποτελεσμάτων των αγώνων. Για τον σκοπό αυτό εφαρμόζονται αλγόριθμοι νευρωνικών δικτύων και μηχανικής μάθησης, ενώ αξιοποιούνται χαρακτηριστικά όπως τα αναμενόμενα γκολ (xG), η φόρμα, τα συστήματα, τα head-to-head στατιστικά, και η σχετική δυναμικότητα των ομάδων. Τα αποτελέσματα των μοντέλων παρουσιάζονται τόσο γραφικά (σε διαγράμματα) όσο και μέσα από ένα διαδραστικό γραφικό περιβάλλον (GUI) που δημιουργήθηκε στο πλαίσιο της εργασίας.

Abstract

The continuous advancement of computer technology and data analysis has significantly impacted the field of sports. In modern football, especially at the professional level, many clubs maintain dedicated data analytics departments to identify strengths and weaknesses of both their own team and their opponents. Similarly, bookmakers utilize predictive models to estimate match outcomes and adjust betting odds accordingly.

This thesis focuses on analyzing and predicting football match outcomes using data from the English Premier League for the seasons 2019–2024. A range of features is extracted, including expected goals (xG), recent form, formations, head-to-head statistics, and relative team strength (power ranking). Various machine learning algorithms and neural network models are applied to evaluate their predictive performance. The results are presented through visualizations and an interactive Graphical User Interface (GUI) developed as part of this work.

Περιεχόμενα

Ευχαριστίες	i
Περίληψη	iii
Abstract	v
1 Εισαγωγή	1
1.1 Ιδέα και στόχοι διπλωματικής εργασίας	1
1.2 Οργάνωση διπλωματικής εργασίας	1
1.3 Παρόμοιες εργασίες	2
2 Μηχανική μάθηση	3
2.1 Κατηγορίες μηχανικής μάθησης	3
2.1.1 Επιβλεπόμενη μάθηση - Supervised Learning	3
2.1.2 Μη Επιβλεπόμενη μάθηση - Unsupervised Learning	3
2.1.3 Ημι-επιβλεπόμενη μάθηση - Semi-supervised Learning	4
2.1.4 Ενισχυτική μάθηση - Reinforcement Learning	4
2.2 Ταξινόμηση - Classification	4
2.2.1 Είδη ταξινόμησης	4
2.2.2 Ταξινόμηση στην μηχανική μάθηση	5
2.3 Παλινδρόμηση - Regression	7
2.3.1 Εξαρτημένη Μεταβλητή (Target)	7
2.3.2 Ανεξάρτητες Μεταβλητές (Features)	7
2.4 Διαδικασία μηχανικής μάθησης	7
2.4.1 Ορισμός Προβλήματος	7
2.4.2 Συλλογή Δεδομένων	7
2.4.3 Καθαρισμός και Προεπεξεργασία Δεδομένων	8
2.4.4 Εξερευνητική Ανάλυση Δεδομένων - Exploratory Data Analysis (EDA)	8
2.4.5 Μηχανική και Επιλογή Χαρακτηριστικών	8
2.4.6 Επιλογή Μοντέλου	9
2.4.7 Εκπαίδευση Μοντέλου	9
2.4.8 Αξιολόγηση και Βελτίωση Μοντέλου	9

2.4.9	Ανάπτυξη Μοντέλου	10
3	Νευρωνικό δίκτυο	11
3.1	Ορισμός νευρωνικού δικτύου	11
3.2	Λειτουργία νευρωνικού δικτύου	11
3.2.1	Επίπεδο εισόδου - input layer	11
3.2.2	Κρυφό επίπεδο - hidden layer	11
3.2.3	Επίπεδο εξόδου - output layer	11
3.3	Συνάρτηση ενεργοποίησης	12
3.3.1	ReLU	12
3.3.2	SoftMax	13
3.4	Βελτιστοποιητής και συναρτήσεις απώλειας	13
3.4.1	Adam - Adaptive Moment Estimation	14
3.4.2	Απώλεια διαστευρούμενης εντροπίας - Cross-Entropy Loss	14
3.5	Εκπαίδευση	15
3.5.1	Οπισθοδιάδοση - Backpropagation	15
3.5.2	Εμπρόσθια διάδοση - Forward Propagation	15
3.6	Κανονικοποίηση - Regularization	16
3.6.1	Υπερπροσαρμογή - Overfitting	16
3.6.2	Dropout	16
4	Χρησιμοποιημένα μοντέλα	17
4.1	MLP - Multi-Layer Perception	17
4.1.1	Στοιχεία του MLP	17
4.2	Random Forest	17
4.2.1	Κύρια χαρακτηριστικά του Random Forest	18
4.2.2	Υποθέσεις του Random Forest	18
4.3	XGBoost - eXtreme Gradient Boosting	19
4.3.1	Πώς λειτουργεί το XGBoost	19
4.4	Logistic Regression	20
4.4.1	Τύποι Logistic Regression	20
4.4.2	Πως λειτουργεί το Logistic Regression	21
4.5	LightGBM - Light Gradient Boosting Machine	23
4.5.1	Κύριες Παράμετροι του LightGBM	24
4.6	Τρόποι υπολογισμού επίδοσης μοντέλων	25
5	Περιγραφή των Δεδομένων	27
5.1	Πηγή Δεδομένων	27
5.2	Επεξεργασία Συνόλου Δεδομένων	27
5.2.1	Συντομογραφίες Ομάδων	27
5.2.2	Αφαίρεση Διπλότυπων Εγγραφών	28
5.3	Επεξήγηση Μεταβλητών	28

5.3.1	Ημερομηνία και Ώρα Αγώνα	28
5.3.2	Διοργάνωση και Αγωνιστική Περίοδος	28
5.3.3	Έδρα	28
5.3.4	Τελικό Αποτέλεσμα και Γκολ	28
5.3.5	Δεδομένα Σουτ	29
5.3.6	Στατικές Φάσεις	29
5.3.7	Σύστημα Ομάδας	29
5.3.8	Ομάδα και Αντίπαλος	30
5.3.9	Λοιπά Στοιχεία	30
6	Εργαλεία που χρησιμοποιήθηκαν	31
6.1	Python	31
6.1.1	Numpy	31
6.1.2	Scikit-Learn	31
6.1.3	Matplotlib	32
6.1.4	Tkinter	32
6.1.5	PySpark	33
6.1.6	Pytorch	33
6.1.7	Queue	34
6.1.8	Threading	34
6.1.9	functools	34
7	Υλοποίηση εργασίας	35
7.1	Επεξεργασία δεδομένων	35
7.2	Χρήση GUI	35
7.3	Εξαγωγή δεδομένων	36
7.3.1	Φόρμα Ομάδας	36
7.3.2	Αντιμετώπιση Αντιπάλου Συστήματος	36
7.3.3	Power Ranking	36
7.3.4	Ιστορικό Προηγούμενων Αναμετρήσεων	36
7.4	Εκπαίδευση μοντέλων	37
7.4.1	Εκπαίδευση με MLP	37
7.4.2	Εκπαίδευση με Random Forest	38
7.4.3	Εκπαίδευση με XGBoost	39
7.4.4	Εκπαίδευση με Logistic Regression	40
7.4.5	Εκπαίδευση με LightGBM	40
7.5	Πρόβλεψη αποτελέσματος	42
8	Αποτελέσματα	43
8.1	Αποτελέσματα MLP	43
8.2	Αποτελέσματα Random Forest	45
8.3	Αποτελέσματα XGBoost	48

8.4	Αποτελέσματα Logistic Regression	50
8.5	Αποτελέσματα LightGBM	53
9	Επίλογος	57
9.1	Συμπεράσματα	57
9.2	Ιδέες για μελλοντικές επεκτάσεις	57

Κεφάλαιο 1

Εισαγωγή

1.1 Ιδέα και στόχοι διπλωματικής εργασίας

Η πρόοδος της τεχνητής νοημοσύνης τα τελευταία χρόνια είναι ραγδαία, επηρεάζοντας σημαντικά πολλούς τομείς της καθημερινής ζωής. Ένας από αυτούς είναι και ο αθλητισμός, με το ποδόσφαιρο που είναι το δημοφιλέστερο άθλημα παγκοσμίως να μην αποτελεί εξαίρεση.

Στο πλαίσιο της παρούσας διπλωματικής εργασίας, στόχος είναι η διερεύνηση της δυνατότητας πρόβλεψης του αποτελέσματος ποδοσφαιρικών αγώνων (νίκη γηπεδούχου, ισοπαλία, νίκη φιλοξενούμενου) μέσω της εφαρμογής τεχνικών μηχανικής μάθησης και νευρωνικών δικτύων.

Για τον σκοπό αυτό, θα σχεδιαστεί ένα σύστημα το οποίο θα εκπαιδεύεται με επιβλεπόμενη μάθηση χρησιμοποιώντας επιλεγμένα χαρακτηριστικά (features) από δεδομένα αγώνων της Premier League. Μέσα από τη μελέτη διαφορετικών αλγορίθμων και τη συγκριτική αξιολόγηση των αποτελεσμάτων τους, θα εξεταστεί πόσο εφικτή και αξιόπιστη μπορεί να είναι η πρόβλεψη ποδοσφαιρικών αποτελεσμάτων με χρήση τεχνητής νοημοσύνης.

1.2 Οργάνωση διπλωματικής εργασίας

Η εργασία έχει χωριστεί σε εννέα κεφάλαια. Το πρώτο κεφάλαιο περιέχει την εισαγωγή της διπλωματικής εργασίας με κάποιες βασικές πληροφορίες για τους στόχους και τον τρόπο επίτευξης της. Στο δεύτερο κεφάλαιο γίνεται εκτενής αναφορά στο θεωρητικό μέρος της μηχανικής μάθησης στο τι είναι και στους τρόπους που λειτουργεί. Στο τρίτο κεφάλαιο γίνεται επίσης εκτενής αναφορά σε αυτή την περίπτωση στο θεωρητικό μέρος των νευρωνικών δικτύων στο τι είναι και στο τρόπο λειτουργίας του. Στο τέταρτο κεφάλαιο γίνεται θεωρητική ανάλυση των μοντέλων που χρησιμοποιήθηκαν και στο τι ιδιότητες έχουν. Στο πέμπτο κεφάλαιο αναλύεται η πηγή δεδομένων που χρησιμοποιήθηκε για την εργασία. Στο έκτο κεφάλαιο αναλύονται οι βιβλιοθήκες και η γλώσσα προγραμματισμού που χρησιμοποιήθηκε για την επίτευξη του κώδικα. Στο έβδομο κεφάλαιο γίνεται εκτενής αναφορά στην δημιουργία και τις ειδικότητες του κώδικα που χρησιμοποιήθηκε. Στο όγδοο κεφάλαιο εμφανίζονται τα αποτελέσματα με εξήγηση για τις επιδόσεις του καθενός μοντέλου. Το τελευταίο κεφάλαιο

είναι ο επίλογος και αναφέρονται συμπεράσματα και ιδέες για μελλοντικές εργασίες

1.3 Παρόμοιες εργασίες

Έχουν υπάρξει παρόμοιου είδους διπλωματικές και από άλλους φοιτητές που βοήθησαν στην δομή αλλά και στην καθοδήγηση της συγκεκριμένης εργασίας. Μερικές από αυτές είναι οι παρακάτω:

- ‘ΠΡΟΒΛΕΨΗ ΑΠΟΤΕΛΕΣΜΑΤΟΣ ΕΛΛΗΝΙΚΩΝ ΑΓΩΝΩΝ ΜΕ ΤΗΝ ΒΟΗΘΕΙΑ ΜΗΧΑΝΙΚΗΣ ΜΑΘΗΣΗΣ’ από τον φοιτητή Ρατσικάλη Γεώργιο.
- ‘ΠΡΟΒΛΕΨΗ ΑΠΟΤΕΛΕΣΜΑΤΩΝ ΠΟΔΟΣΦΑΙΡΙΚΩΝ ΑΓΩΝΩΝ ΜΕ ΤΕΧΝΙΚΕΣ ΜΗΧΑΝΙΚΗΣ ΜΑΘΗΣΗΣ’ από τον φοιτητή Μανούχο Μάριο.
- ‘Πρόβλεψη αγώνων Premier League με χρήση Μηχανικής Μάθησης’ από τον φοιτητή Μητρόπουλο Δημήτριο.
- ‘Εφαρμογή Τεχνητών Νευρωνικών Δικτύων για την πρόβλεψη αποτελεσμάτων και στατιστικών στο (ελληνικό) Ποδόσφαιρο’ από τον φοιτητή Πανάικα Σωτήριο.
- ‘Πρόβλεψη αποτελεσμάτων ποδοσφαιρικών αγώνων με χρήση μηχανικής μάθησης’ από τον φοιτητή Καραγεώργο Αργύρη.

Κεφάλαιο 2

Μηχανική μάθηση

Η μηχανική μάθηση είναι ένα υποσύνολο της τεχνητής νοημοσύνης (Artificial Intelligence). Επικεντρώνεται στη διδασκαλία των υπολογιστών να μαθαίνουν από τα δεδομένα και να βελτιώνονται με την εμπειρία – αντί να είναι ρητά προγραμματισμένοι να το κάνουν. Στη μηχανική μάθηση, οι αλγόριθμοι εκπαιδεύονται για να βρουν μοτίβα και συσχετίσεις σε μεγάλα σύνολα δεδομένων και να λαμβάνουν τις καλύτερες αποφάσεις και προβλέψεις με βάση αυτή την ανάλυση. Οι εφαρμογές μηχανικής μάθησης βελτιώνονται με τη χρήση και γίνονται πιο ακριβείς όσο περισσότερα δεδομένα έχουν πρόσβαση.

2.1 Κατηγορίες μηχανικής μάθησης

Η μηχανική μάθηση αποτελείται από διαφορετικούς τύπους μοντέλων μηχανικής μάθησης, χρησιμοποιώντας διάφορες αλγοριθμικές τεχνικές. Ανάλογα με τη φύση των δεδομένων και το επιθυμητό αποτέλεσμα, ένα από τα τέσσερα μοντέλα μάθησης μπορεί να χρησιμοποιηθεί: επιβλεπόμενο, χωρίς επίβλεψη, ημι-εποπτευόμενο, ή ενισχυτικό:

2.1.1 Επιβλεπόμενη μάθηση - Supervised Learning

Στο δίκτυο δίνονται ζευγάρια διανυσμάτων εισόδου - επιθυμητής εξόδου.. Ο στόχος είναι να μάθει το δίκτυο να αντιστοιχίζει τα δεδομένα εισόδου με τις αντίστοιχες εξόδους, μειώνοντας σταδιακά το σφάλμα μεταξύ της πρόβλεψης και της πραγματικής τιμής. Περιέχει εφαρμογές όπως η ταξινόμηση (classification) και η παλινδρόμηση (regression).

2.1.2 Μη Επιβλεπόμενη μάθηση - Unsupervised Learning

Τα παραδείγματα εκπαίδευσης δεν περιλαμβάνουν την επιθυμητή έξοδο αλλά μόνο τα δεδομένα εισόδου και ο στόχος δεν είναι η εκτίμηση των αποτελεσμάτων από τα δεδομένο εισόδου αλλά η επεξεργασία των δεδομένων εισόδου. Οι εφαρμογές της μη επιβλεπόμενης μάθησης περιλαμβάνουν την ομαδοποίηση (clustering) και την μείωση της διάστασης των δεδομένων (dimensionality reduction).

2.1.3 Ημι-επιβλεπόμενη μάθηση - Semi-supervised Learning

Αυτό το μοντέλο αποτελείται από την εισαγωγή μικρών ποσοτήτων δεδομένων με ετικέτα για να αυξήσει τα σύνολα δεδομένων χωρίς ετικέτα. Ουσιαστικά, τα επισημασμένα δεδομένα ενεργούν για να δώσουν μια αρχή λειτουργίας στο σύστημα και μπορούν να βελτιώσουν σημαντικά την ταχύτητα και την ακρίβεια της μάθησης. Ένας ημι-εποπτευόμενος αλγόριθμος μάθησης καθοδηγεί τη μηχανή να αναλύσει τα επισημασμένα δεδομένα για τις συσχετιζόμενες ιδιότητες που θα μπορούσαν να εφαρμοστούν στα δεδομένα χωρίς ετικέτα. Η ημι-επιβλεπόμενη μάθηση χρησιμοποιείται στην ομιλία και τη γλωσσική ανάλυση, τη σύνθετη ιατρική έρευνα όπως η κατηγοριοποίηση πρωτεϊνών, και την υψηλού επιπέδου ανίχνευση απάτης.

2.1.4 Ενισχυτική μάθηση - Reinforcement Learning

Το μοντέλο ενισχυμένης μάθησης δεν περιλαμβάνει μία έξοδο αλλά, αντίθετα, εισάγει ένα σύνολο επιτρεπόμενων ενεργειών, κανόνων και πιθανών τελικών καταστάσεων. Όταν ο επιθυμητός στόχος του αλγορίθμου είναι σταθερός ή δυαδικός, οι μηχανές μπορούν να μάθουν με το παράδειγμα. Αλλά σε περιπτώσεις όπου το επιθυμητό αποτέλεσμα είναι μεταβλητό, το σύστημα πρέπει να μάθει από την εμπειρία και την ανταμοιβή. Στα μοντέλα ενισχυτικής μάθησης, η «ανταμοιβή» είναι αριθμητική και προγραμματίζεται στον αλγόριθμο ως κάτι που το σύστημα επιδιώκει να συλλέξει. Οι εφαρμογές της ενισχυτικής μάθησης περιλαμβάνουν τη βελτιστοποίηση στρατηγικής και τα αυτόνομα συστήματα.

2.2 Ταξινόμηση - Classification

Η ταξινόμηση μαθαίνει στην μηχανή να κατανέμει τα αντικείμενα σε κατηγορίες. Μαθαίνει μέσω παραδειγμάτων με ετικέτες (labels). Μετά την μάθηση αποφασίζει σε ποια κατηγορία πάει το αντικείμενο.

2.2.1 Είδη ταξινόμησης

Στην ταξινόμηση στην μηχανική μάθηση υπάρχουν τρεις τύποι για να επιτευχθεί που εξαρτάται από πόσα αντικείμενα ή πόσες κλάσεις υπάρχουν και τον τρόπο που είναι οργανωμένες

Δυαδική ταξινόμηση - Binary classification

Είναι ο πιο απλός τρόπος ταξινόμησης διότι κατανέμονται τα δεδομένα σε δύο κατηγορίες οπότε είναι δύο επιλογές (όπως το ΝΑΙ/ΟΧΙ).

Ταξινόμηση πολλαπλών κλάσεων - Multiclass classification

Η Ταξινόμηση πολλών κλάσεων γίνεται κατανομή σε πάνω από δύο κλάσεις. Το μοντέλο επιλέγει αυτό που ταιριάζει καλύτερα με την είσοδο.


Ταξινόμηση πολλαπλών ετικετών - Multi-label classification

Στην ταξινόμηση πολλαπλών ετικετών, ένα μόνο στοιχείο δεδομένων μπορεί να ανήκει σε πολλές κατηγορίες ταυτόχρονα. Σε αντίθεση με την ταξινόμηση πολλαπλών κλάσεων όπου κάθε σημείο δεδομένων ανήκει μόνο σε μία κλάση, η ταξινόμηση πολλαπλών ετικετών επιτρέπει στα σημεία δεδομένων να ανήκουν σε πολλές κλάσεις.

2.2.2 Ταξινόμηση στην μηχανική μάθηση

Η ταξινόμηση περιλαμβάνει την εκπαίδευση ενός μοντέλου χρησιμοποιώντας ένα σύνολο δεδομένων με ετικέτες, όπου κάθε είσοδος αντιστοιχίζεται με τη σωστή ετικέτα εξόδου. Το μοντέλο μαθαίνει μοτίβα και σχέσεις στα δεδομένα, ώστε να μπορεί αργότερα να προβλέψει ετικέτες για νέες, μη ορατές εισόδους. Στη μηχανική μάθηση, η ταξινόμηση λειτουργεί εκπαιδεύοντας ένα μοντέλο να μαθαίνει μοτίβα από δεδομένα με ετικέτες, ώστε να μπορεί να προβλέψει την κατηγορία ή την κλάση των νέων, μη ορατών δεδομένων. Δείτε πώς λειτουργεί:

1. Συλλογή Δεδομένων: Ξεκινάτε με ένα σύνολο δεδομένων όπου κάθε στοιχείο φέρει ετικέτες με τη σωστή κλάση (για παράδειγμα, "γάτα" ή "σκύλος").
2. Εξαγωγή Χαρακτηριστικών: Το σύστημα αναγνωρίζει χαρακτηριστικά (όπως χρώμα, σχήμα ή υφή) που βοηθούν στη διάκριση μιας κλάσης από μια άλλη. Αυτά τα χαρακτηριστικά είναι αυτά που χρησιμοποιεί το μοντέλο για να κάνει προβλέψεις.
3. Εκπαίδευση Μοντέλου: Ταξινόμηση - ο αλγόριθμος μηχανικής μάθησης χρησιμοποιεί τα δεδομένα με ετικέτες για να μάθει πώς να αντιστοιχίζει τα χαρακτηριστικά στη σωστή κλάση. Αναζητά μοτίβα και σχέσεις στα δεδομένα.
4. Αξιολόγηση Μοντέλου: Μόλις εκπαιδευτεί το μοντέλο, δοκιμάζεται σε νέα, μη ορατά δεδομένα για να ελεγχθεί με πόσο ακριβή τρόπο μπορεί να ταξινομήσει τα στοιχεία.
5. Πρόβλεψη: Αφού εκπαιδευτεί και αξιολογηθεί, το μοντέλο μπορεί να χρησιμοποιηθεί για την πρόβλεψη της κλάσης των νέων δεδομένων με βάση τα χαρακτηριστικά που έχει μάθει.
6. Αξιολόγηση Μοντέλου: Η αξιολόγηση ενός μοντέλου ταξινόμησης είναι ένα βασικό βήμα στη μηχανική μάθηση. Μας βοηθά να ελέγξουμε πόσο καλά αποδίδει το μοντέλο και πόσο καλό είναι στο χειρισμό νέων, απαρατήρητων δεδομένων. Ανάλογα με το πρόβλημα και τις ανάγκες, μπορούμε να χρησιμοποιήσουμε διαφορετικές μετρήσεις για να μετρήσουμε την απόδοσή του.



Σχήμα 2.1: Παράδειγμα Classification για σκύλους και γάτες βάση υψούς, σχήματος και χρώματος. [13]

2.3 Παλινδρόμηση - Regression

Η παλινδρόμηση είναι μια θεμελιώδης έννοια στον τομέα της μηχανικής μάθησης, ειδικά στο πλαίσιο της προγνωστικής μοντελοποίησης. Είναι μια στατιστική προσέγγιση που στοχεύει να δημιουργήσει μια σχέση μεταξύ μιας εξαρτημένης μεταβλητής και μιας ή περισσότερων ανεξάρτητων μεταβλητών. Αυτή η σχέση χρησιμοποιείται στη συνέχεια για την πρόβλεψη μελλοντικών αποτελεσμάτων ή την εκτίμηση της τιμής της εξαρτημένης μεταβλητής με βάση τις δεδομένες ανεξάρτητες μεταβλητές. Στην παλινδρόμηση έχουμε δύο τύπους μεταβλητών:

2.3.1 Εξαρτημένη Μεταβλητή (Target)

Η μεταβλητή που προσπαθούμε να προβλέψουμε, π.χ. τιμή κατοικίας.

2.3.2 Ανεξάρτητες Μεταβλητές (Features)

Οι μεταβλητές εισόδου που επηρεάζουν την πρόβλεψη, π.χ. τοποθεσία, αριθμός δωματίων.

2.4 Διαδικασία μηχανικής μάθησης

Για να επιτευχθεί ένα μοντέλο μηχανικής μάθησης με δομημένο τρόπο πρέπει να επιτευχθούν διάφορα βήματα. Κάθε βήμα παίζει κρίσιμο ρόλο στη διασφάλιση της επιτυχίας και της αποτελεσματικότητας του μοντέλου μηχανικής μάθησης. Μέσω αυτών λύνονται σύνθετα προβλήματα, απόκτηση πληροφοριών που βασίζονται σε δεδομένα (data-driven insights) και δημιουργούνται κλιμακώσιμα και βιώσιμα μοντέλα.

2.4.1 Ορισμός Προβλήματος

Κατά την αρχική αυτή φάση, είναι απαραίτητο να εντοπιστεί και να διατυπωθεί με σαφήνεια το επιχειρησιακό πρόβλημα. Η σωστή πλαίσιωση του προβλήματος θέτει τα θεμέλια για την σωστή υλοποίηση της μηχανικής μάθησης. Στοιχεία όπως οι στόχοι του έργου, τα επιθυμητά αποτελέσματα και το εύρος του προβλήματος καθορίζονται προσεκτικά σε αυτό το στάδιο.

- **Συνεργασία:** Συνεργασία με τα εμπλεκόμενα μέρη για κατανόηση και ορισμό του προβλήματος.
- **Σαφήνεια:** Διατύπωση των στόχων, των επιθυμητών αποτελεσμάτων και του εύρους του έργου.
- **Θεμελίωση:** Θέσπιση σταθερής βάσης για τη διαδικασία μηχανικής μάθησης.

2.4.2 Συλλογή Δεδομένων

Μετά τον καθορισμό του προβλήματος, η διαδικασία συνεχίζεται με τη συλλογή των δεδομένων. Η φάση αυτή περιλαμβάνει τη συστηματική συλλογή συνόλων δεδομένων που θα

χρησιμοποιηθούν για την εκπαίδευση του μοντέλου. Η ποιότητα και η ποικιλομορφία των δεδομένων επηρεάζουν άμεσα τη γενίκευση και την αξιοπιστία του μοντέλου.

- **Συνάφεια:** Τα δεδομένα πρέπει να σχετίζονται με το πρόβλημα και να περιέχουν τα απαραίτητα χαρακτηριστικά.
- **Ποιότητα:** Διασφάλιση ακρίβειας και ηθικής χρήσης των δεδομένων.
- **Ποσότητα:** Συλλογή επαρκούς όγκου δεδομένων για την εκπαίδευση ενός ισχυρού μοντέλου.
- **Ποικιλομορφία:** Συμπερίληψη διαφορετικών περιπτώσεων ώστε να καλύπτονται περισσότερα σενάρια.

2.4.3 Καθαρισμός και Προεπεξεργασία Δεδομένων

Με τη συλλογή των δεδομένων ολοκληρωμένη, ακολουθεί ο καθαρισμός και η προεπεξεργασία. Τα ακατέργαστα δεδομένα συχνά περιέχουν ασυνέπειες, ελλείψεις και θόρυβο, τα οποία ενδέχεται να επηρεάσουν αρνητικά την ακρίβεια του μοντέλου.

- **Καθαρισμός:** Αντιμετώπιση ελλিপών τιμών, ακραίων τιμών και ασυνεπειών.
- **Προεπεξεργασία:** Κανονικοποίηση, κωδικοποίηση κατηγορικών μεταβλητών και ενοποίηση μορφών.
- **Ποιότητα Δεδομένων:** Μετατροπή των δεδομένων σε κατάλληλη μορφή για ανάλυση και εκπαίδευση.

2.4.4 Εξερευνητική Ανάλυση Δεδομένων - Exploratory Data Analysis (EDA)

Η εξερευνητική ανάλυση επιτρέπει την αναγνώριση προτύπων και δομών στα δεδομένα. Αποκαλύπτει πολύτιμες πληροφορίες που βοηθούν στην κατανόηση του συνόλου δεδομένων και στην υποστήριξη αποφάσεων.

- **Εξερεύνηση:** Χρήση στατιστικών και οπτικών εργαλείων για αναγνώριση προτύπων.
- **Τάσεις:** Εντοπισμός τάσεων και πιθανών προβλημάτων στα δεδομένα.
- **Ενημερωμένες Αποφάσεις:** Υποστήριξη επιλογών για μηχανική χαρακτηριστικών και επιλογή μοντέλου.

2.4.5 Μηχανική και Επιλογή Χαρακτηριστικών

Η φάση αυτή περιλαμβάνει τη δημιουργία ή μετασχηματισμό χαρακτηριστικών που ενισχύουν την ακρίβεια του μοντέλου, καθώς και την επιλογή εκείνων που είναι πιο σημαντικά για την πρόβλεψη.

- **Μηχανική Χαρακτηριστικών:** Δημιουργία ή τροποποίηση χαρακτηριστικών για καλύτερη αναπαράσταση.
- **Επιλογή Χαρακτηριστικών:** Εντοπισμός του πιο σημαντικού υποσυνόλου χαρακτηριστικών.
- **Εξειδίκευση:** Χρήση γνώσης του πεδίου για ουσιαστικά χαρακτηριστικά.
- **Βελτιστοποίηση:** Ισορροπία μεταξύ ακρίβειας και υπολογιστικού κόστους.

2.4.6 Επιλογή Μοντέλου

Η επιλογή του κατάλληλου μοντέλου είναι καθοριστική για την επιτυχία της πρόβλεψης. Η απόφαση αυτή εξαρτάται από τη φύση των δεδομένων και την πολυπλοκότητα του προβλήματος.

- **Στοχοθέτηση:** Επιλογή μοντέλου που ευθυγραμμίζεται με το πρόβλημα και τα χαρακτηριστικά των δεδομένων.
- **Πολυπλοκότητα:** Εκτίμηση της δυσκολίας του προβλήματος.
- **Αξιολόγηση:** Ανάλυση απόδοσης, ερμηνευσιμότητας και κλιμάκωσης.
- **Πειραματισμός:** Δοκιμή διαφορετικών μοντέλων για εύρεση της βέλτιστης λύσης.

2.4.7 Εκπαίδευση Μοντέλου

Σε αυτό το στάδιο, το μοντέλο εκπαιδεύεται με χρήση ιστορικών δεδομένων, ώστε να μάθει μοτίβα και σχέσεις που θα το βοηθήσουν στις προβλέψεις.

- **Εκπαίδευση:** Ανάλυση ιστορικών δεδομένων για αναγνώριση σχέσεων.
- **Επανάληψη:** Προσαρμογή παραμέτρων με στόχο τη μείωση του σφάλματος.
- **Βελτιστοποίηση:** Ρύθμιση του μοντέλου για μέγιστη ακρίβεια.
- **Επικύρωση:** Έλεγχος απόδοσης σε άγνωστα δεδομένα.

2.4.8 Αξιολόγηση και Βελτίωση Μοντέλου


Το μοντέλο αξιολογείται με χρήση μετρικών απόδοσης. Αν δεν επιτυγχάνει τα επιθυμητά αποτελέσματα, ακολουθεί βελτίωση μέσω τροποποίησης υπερπαραμέτρων.

- **Μετρικές:** Χρήση δεικτών όπως ακρίβεια, precision, recall, F1.
- **Ανάλυση:** Εντοπισμός δυνατών και αδύναμων σημείων.
- **Βελτιστοποίηση:** Προσαρμογή μοντέλου μέσω υπερπαραμέτρων.
- **Αξιοπιστία:** Διασφάλιση ότι το μοντέλο είναι ικανό για προβλέψεις στον πραγματικό κόσμο.

2.4.9 Ανάπτυξη Μοντέλου

Μετά την επιτυχή αξιολόγηση, το μοντέλο αναπτύσσεται σε πραγματικό περιβάλλον. Ενσωματώνεται σε συστήματα λήψης αποφάσεων και παρακολουθείται συνεχώς.

- **Ενσωμάτωση:** Σύνδεση του μοντέλου με υπάρχουσες διαδικασίες ή συστήματα.
- **Αποφάσεις:** Χρήση των προβλέψεων για υποστήριξη επιχειρησιακών αποφάσεων.
- **Εφαρμοσιμότητα:** Μετατροπή θεωρητικών αποτελεσμάτων σε πρακτικές λύσεις.
- **Βελτίωση:** Συνεχής παρακολούθηση και προσαρμογή του μοντέλου για διατήρηση της απόδοσης.



Σχήμα 2.2: Κύκλος ζωής μηχανικής μάθησης [37]

Κεφάλαιο 3

Νευρωνικό δίκτυο

3.1 Ορισμός νευρωνικού δικτύου

Τα τεχνητά νευρωνικά δίκτυα είναι μια μορφή μηχανικής μάθησης εμπνευσμένο από το Κεντρικό Νευρολογικό σύστημα. Η χρήση τους είναι να βρίσκουν λύσεις σε προβλήματα ανθρώπινου παράγοντα όπως Πρόβλεψη, χρονοπρογραμματισμός, αναγνώριση προτύπων και μπορεί να χρησιμοποιηθεί σε θέματα ιατρικής, χρηματοοικονομικών, μετεωρολογικούς, στρατιωτικούς και διάφορα άλλα. [4]

3.2 Λειτουργία νευρωνικού δικτύου

Ένα βασικό νευρωνικό δίκτυο αποτελείται από κυρίως τρία επίπεδα τεχνικών νευρώνων.

3.2.1 Επίπεδο εισόδου - input layer

Είναι το αρχικό επίπεδο και λαμβάνει τα χαρακτηριστικά των δεδομένων.

3.2.2 Κρυφό επίπεδο - hidden layer


Είναι το ενδιάμεσο επίπεδο και ο σκοπός είναι να μετατραπεί σε κάτι που να μπορεί να χρησιμοποιηθεί στο επίπεδο εξόδου. Αυτό γίνεται λαμβάνοντας βάρη (weights) ώστε να γίνεται καλύτερη συσχέτιση είσοδου - εξόδου και τα μεταφέρει στο επόμενο επίπεδο χάρη μιας συνάρτησης ενεργοποίησης. Η επεξεργασία αυτή αφήνει στο δίκτυο να μάθει μη γραμμικές σχέσεις μεταξύ εισόδου εξόδου

Βάρη (Weights)

Τα βάρη είναι αριθμητικές τιμές που προσαρμόζονται από προηγούμενα επίπεδα κατά την εκπαίδευση του νευρωνικού δικτύου

3.2.3 Επίπεδο εξόδου - output layer

Είναι το τελικό επίπεδο που οδηγείται στην έξοδο του δικτύου.



Σχήμα 3.1: Ένα απλό νευρωνικό δίκτυο. [43]

3.3 Συνάρτηση ενεργοποίησης


Η Συνάρτηση ενεργοποίησης έχει κρίσιμο ρόλο στην μάθηση νευρωνικών δικτύων. Εισάγει μη γραμμικές ιδιότητες στο δίκτυο διευκολύνοντας στην επίλυση σύνθετων προβλημάτων. Υπάρχουν τέσσερις κύριες κατηγορίες συναρτήσεων ενεργοποίησης οι οποίες είναι βηματική (step transfer function), γραμμική (linear transfer function), μη γραμμική (non-linear transfer function), στοχαστική (stochastic transfer function) και οι πιο γνωστές είναι η sigmoid, ReLU, SoftMax, tanh.

3.3.1 ReLU

Η συνάρτηση ενεργοποίησης ReLU (Rectified Linear Unit) είναι μια μη γραμμική συνάρτηση και είναι από τα δημοφιλέστερα είδη συναρτήσεων ενεργοποίησης λόγω της απλότητας και αποδοτικότητας του. Η ιδιότητα της είναι να διαπερνούν οι θετικές τιμές αμετάβλητες ενώ ορίζει στο μηδέν τις αρνητικές. Αυτό διευκολύνει το νευρωνικό δίκτυο ώστε να κρατήσει την απαραίτητη πολυπλοκότητα που χρειάζεται. Ο ορισμός της συνάρτησης ReLU είναι:

$$f(x) = \text{ReLU}(x) = \max(0, x)$$

$$f(x) = \begin{cases} x, & \text{if } x > 0 \\ 0, & \text{if } x \leq 0 \end{cases}$$



Σχήμα 3.2: Το γράφημα της ReLU. [26]

3.3.2 SoftMax

Το SoftMax είναι μια συνάρτηση ενεργοποίησης εμπνευσμένη από την στατιστική μηχανική και θεωρία πληροφορίας και χρησιμοποιείται συνήθως σε πολυ-ταξινομημένα προβλήματα. Η ιδιότητα του είναι να μετατρέπει ένα διάνυσμα αποτελεσμάτων πρόβλεψης σε πιθανότητες. Οι πιθανότητες είναι κατανομημένες έτσι ώστε το άθροισμα των πιθανοτήτων να ισούται με 1. [6]

$$\text{softmax}(z_i) = \frac{e^{z_i}}{\sum_{j=1}^K e^{z_j}}$$

Όπου:

- z_i : η είσοδος για την i -οστή κατηγορία.
- K : ο συνολικός αριθμός κατηγοριών.
- e^{z_i} : ο εκθετικός μετασχηματισμός της τιμής z_i .
- Ο παρονομαστής είναι το άθροισμα όλων των e^{z_j} , δηλαδή $\sum_{j=1}^K e^{z_j}$, ώστε η έξοδος να είναι πιθανότητες που αθροίζονται σε 1.

3.4 Βελτιστοποιητής και συναρτήσεις απώλειας

Στη μηχανική μάθηση, οι βελτιστοποιητές και οι συναρτήσεις απώλειας είναι δύο θεμελιώδη στοιχεία που βοηθούν στη βελτίωση της απόδοσης ενός μοντέλου. Απώλεια αξιολογεί την αποτελεσματικότητα ενός μοντέλου υπολογίζοντας τη διαφορά μεταξύ των αναμενόμενων και των πραγματικών εξόδων. Ένας βελτιστοποιητής βελτιώνει το μοντέλο προσαρμόζοντας τις

παραμέτρους του (βάρη weights και μεροληψίες biases) για να ελαχιστοποιήσει την τιμή της συνάρτησης απώλειας.

3.4.1 Adam - Adaptive Moment Estimation

Το Adam είναι ένας βελτιστοποιητής που χρησιμοποιεί τόσο την πρώτη ροπή (μέσος όρος) όσο και τη δεύτερη ροπή (διακύμανση) των μεροληψιών για να προσαρμόσει τον ρυθμό εκμάθησης για κάθε παράμετρο. [23]

$$\text{Ενημέρωση πρώτης ροπής: } m_t = \beta_1 \cdot m_{t-1} + (1 - \beta_1) \cdot \nabla J(\theta_t)$$

$$\text{Ενημέρωση δεύτερης ροπής: } v_t = \beta_2 \cdot v_{t-1} + (1 - \beta_2) \cdot (\nabla J(\theta_t))^2$$

$$\text{Διόρθωση μεροληψίας: } \hat{m}_t = \frac{m_t}{1 - \beta_1^t}, \quad \hat{v}_t = \frac{v_t}{1 - \beta_2^t}$$

$$\text{Ενημέρωση παραμέτρων: } \theta_{t+1} = \theta_t - \frac{\alpha}{\sqrt{\hat{v}_t} + \varepsilon} \cdot \hat{m}_t$$

Όπου:

- β_1 και β_2 είναι οι ρυθμοί απόσβεσης για την πρώτη και τη δεύτερη ροπή αντίστοιχα.
- ε είναι μια πολύ μικρή σταθερά που αποτρέπει τη διαίρεση με το μηδέν.

3.4.2 Απώλεια διαστυρωμένης εντροπίας - Cross-Entropy Loss

Στην μηχανική μάθηση για θέματα ταξινόμησης, το μοντέλο προβλέπει την πιθανότητα ενός δείγματος (sample) να ανήκει σε μια συγκεκριμένη κλάση. Δεδομένου ότι κάθε δείγμα μπορεί να ανήκει μόνο σε μια συγκεκριμένη κλάση, η πραγματική τιμή πιθανότητας θα είναι 1 για τη συγκεκριμένη κλάση και 0 για την/τις άλλη/ες κλάση/ές. Η διαστυρωμένη εντροπία μετρά τη διαφορά μεταξύ της προβλεπόμενης πιθανότητας και της πραγματικής πιθανότητας. Η Απώλεια Διαστυρωμένης Εντροπίας προκύπτει από τις αρχές της εκτίμησης μέγιστης πιθανοφάνειας όταν εφαρμόζεται στο έργο της ταξινόμησης. Η μεγιστοποίηση της πιθανοφάνειας ισοδυναμεί με την ελαχιστοποίηση της αρνητικής λογαριθμικής πιθανοφάνειας. [20]

3.5 Εκπαίδευση

Η εκπαίδευση ενός νευρωνικού δικτύου είναι η διαδικασία κατά την οποία το δίκτυο μαθαίνει να εκτελεί συγκεκριμένες εργασίες, χρησιμοποιώντας δεδομένα. Ο τρόπος με τον οποίο το δίκτυο εκπαιδεύεται εξαρτάται από τη μέθοδο μάθησης που εφαρμόζεται. Υπάρχουν δύο βασικές κατηγορίες μεθόδων:

3.5.1 Οπισθοδιάδοση - Backpropagation

Η οπισθοδιάδοσα είναι μια μέθοδος εκμάθησης νευρωνικών δικτύων και χρησιμοποιείται κυρίως στην επιβλεπόμενη μάθηση και κάποιες φορές στην ενισχυτική μάθηση. Χρησιμοποιείται για να υπολογίσει τα σφάλματα μεταξύ των προβλέψεων του δικτύου και των πραγματικών τιμών προσαρμόζοντας τα βάρη και τις μεροληψίες (biases) ώστε να ελαχιστοποιηθεί αυτό το σφάλμα. Η οπισθοδιάδοση έχει δύο βήματα: Το εμπρός πέρασμα Forward Pass και το πίσω πέρασμα Backward Pass [12]

Εμπρός πέρασμα - Forward Pass

Αρχικά ένα διάνυσμα εισόδου εφαρμόζεται στους νευρώνες εισόδου του δικτύου και διαδίδεται από επίπεδο σε επίπεδο. Όσο εκτελείται το εμπρός πέρασμα, τα βάρη παραμένουν αμετάβλητα. Στο τέλος παράγεται ένα σύνολο από εξόδους ως η πραγματική απόκριση του δικτύου.

Πίσω πέρασμα - Backward Pass

Σε αυτό το στάδιο τα βάρη ανανεώνονται με βάση τον κανόνα διόρθωσης που παράγεται από το εμπρός πέρασμα. Συγκεκριμένα, η πραγματική απόκριση του δικτύου αφαιρείται από την επιθυμητή απόκριση για την παραγωγή ενός σήματος λάθους, το οποίο διαδίδεται προς τα πίσω, δηλαδή αντίθετα από την κατεύθυνση των συνδέσεων. Η ανανέωση των βαρών γίνεται με τέτοιο τρόπο, έτσι ώστε η πραγματική απόκριση του δικτύου να πλησιάζει την επιθυμητή απόκριση.

3.5.2 Εμπρόσθια διάδοση - Forward Propagation

Η εμπρόσθια διάδοση (forward propagation) είναι η διαδικασία κατά την οποία τα δεδομένα εισόδου διαδίδονται μέσω των επιπέδων ενός νευρωνικού δικτύου, από το επίπεδο εισόδου προς το επίπεδο εξόδου, με σκοπό την παραγωγή προβλεπόμενης τιμής. Σε κάθε κρυφό και έξοδο επίπεδο, πραγματοποιείται αρχικά ο υπολογισμός του σταθμισμένου αθροίσματος (pre-activation), δηλαδή ο γραμμικός συνδυασμός των εισερχόμενων τιμών και των αντίστοιχων βαρών, μαζί με τον όρο μεροληψίας (bias). Στη συνέχεια εφαρμόζεται μια μη γραμμική συνάρτηση ενεργοποίησης, ώστε το δίκτυο να αποκτήσει ικανότητα μη γραμμικής μάθησης.

Η κατεύθυνση της ροής των δεδομένων είναι αυστηρά προς τα εμπρός, χωρίς ανατροφοδότηση, γεγονός που αποτρέπει τη δημιουργία κυκλικών εξαρτήσεων και διασφαλίζει την ορθή

παραγωγή εξόδου. Η εμπρόσθια διάδοση είναι βασική για τη φάση πρόβλεψης αλλά και για τον υπολογισμό του σφάλματος που χρησιμοποιείται στη φάση της οπισθοδιάδοσης. [34]

3.6 Κανονικοποίηση - Regularization

Η κανονικοποίηση είναι ένα σύνολο μεθόδων για τη μείωση του overfitting σε μοντέλα μηχανικής μάθησης. Συνήθως, η κανονικοποίηση ανταλλάσσει μια πολύ μικρή μείωση στην ακρίβεια της εκπαίδευσης με μια αύξηση στη γενικευσιμότητα. [33]

3.6.1 Υπερπροσαρμογή - Overfitting

Η υπερπροσαρμογή συμβαίνει όταν ένα μοντέλο μαθαίνει πάρα πολλά από τα δεδομένα εκπαίδευσης, συμπεριλαμβανομένων λεπτομερειών που δεν έχουν σημασία (πχ θόρυβος).

3.6.2 Dropout

Το Dropout είναι μια τεχνική κανονικοποίησης που τυχαία αγνοεί ή απορρίπτει εξόδους την στιγμή της εκπαίδευσης και χρησιμοποιείται για να αποτρέψει το overfitting. Πρακτικά αυτό που συμβαίνει κατά το overfitting είναι η δημιουργία εξαρτήσεων μεταξύ κάποιων νευρώνων κατά την εκπαίδευση του δικτύου. Με αυτή τη μέθοδο εξαλείφονται οι εξαρτήσεις αυτές αφού για κάθε ένα από τα δεδομένα εισόδου εκπαιδεύεται διαφορετικό υποσύνολο των νευρώνων του δικτύου. [22]

Κεφάλαιο 4

Χρησιμοποιημένα μοντέλα

4.1 MLP - Multi-Layer Perception

Το MLP αποτελείται από πλήρως συνδεδεμένα πυκνά επίπεδα που μετασχηματίζουν τα δεδομένα εισόδου από τη μία διάσταση στην άλλη. Ονομάζεται πολυεπίπεδο (multilayer) επειδή περιέχει ένα επίπεδο εισόδου, ένα ή περισσότερα κρυφά επίπεδα και ένα επίπεδο εξόδου. Ο σκοπός ενός MLP είναι να μοντελοποιήσει σύνθετες συσχετίσεις μεταξύ εισόδων και εξόδων.

4.1.1 Στοιχεία του MLP

- **Είσοδος (Input Layer):** Κάθε νευρώνας σε αυτό το επίπεδο αντιστοιχεί σε ένα χαρακτηριστικό εισόδου. Για παράδειγμα, αν υπάρχουν τρία χαρακτηριστικά εισόδου, τότε το επίπεδο εισόδου θα περιλαμβάνει τρεις νευρώνες.
- **Κρυφά Επίπεδα (Hidden Layers):** Το MLP μπορεί να περιλαμβάνει οποιονδήποτε αριθμό κρυφών επιπέδων, το καθένα με οποιονδήποτε αριθμό νευρώνων. Αυτά τα επίπεδα επεξεργάζονται τις πληροφορίες που λαμβάνουν από το επίπεδο εισόδου.
- **Έξοδος (Output Layer):** Το επίπεδο εξόδου παράγει την τελική πρόβλεψη ή αποτέλεσμα. Αν υπάρχουν πολλαπλές εξόδους, τότε το επίπεδο εξόδου θα έχει αντίστοιχο αριθμό νευρώνων.

Η υπόλοιπη διαδικασία περιέχει τα στοιχεία forward propagation, loss function, backpropagation και optimization που έχουν αναλυθεί στο κεφάλαιο των νευρωνικών δικτύων

4.2 Random Forest


Το Random Forest είναι ένας αλγόριθμος μηχανικής μάθησης που χρησιμοποιεί πολλά δέντρα αποφάσεων για να κάνει καλύτερες προβλέψεις. Κάθε δέντρο εξετάζει διαφορετικά τμήματα των δεδομένων και τα αποτελέσματά τους συνδυάζονται ψηφίζοντας για ταξινόμηση ή υπολογίζοντας τον μέσο όρο για παλινδρόμηση. Αυτό βοηθά στη βελτίωση της ακρίβειας και στη μείωση των σφαλμάτων. [45]

4.2.1 Κύρια χαρακτηριστικά του Random Forest

- **Διαχείριση Ελλιπών Δεδομένων:** Μπορεί να λειτουργήσει ακόμη και όταν λείπουν κάποια δεδομένα, χωρίς να απαιτείται απαραίτητα η συμπλήρωσή τους από τον χρήστη.
- **Ανάδειξη Σημαντικότητας Χαρακτηριστικών:** Παρέχει πληροφορίες για το ποια χαρακτηριστικά (στήλες) είναι πιο σημαντικά για την πρόβλεψη, βοηθώντας στην καλύτερη κατανόηση των δεδομένων.
- **Καλή Απόδοση σε Μεγάλα και Πολύπλοκα Δεδομένα:** Μπορεί να χειριστεί μεγάλα σύνολα δεδομένων με πολλαπλά χαρακτηριστικά χωρίς να επιβραδύνεται ή να χάνει σε ακρίβεια.
- **Ευελιξία σε Διάφορα Είδη Εργασιών:** Μπορεί να χρησιμοποιηθεί τόσο για προβλήματα ταξινόμησης (classification), όπως η πρόβλεψη κατηγοριών ή ετικετών, όσο και για παλινδρόμηση (regression), όπως η πρόβλεψη αριθμητικών τιμών ή ποσοτήτων.

4.2.2 Υποθέσεις του Random Forest

- **Κάθε δέντρο παίρνει ανεξάρτητες αποφάσεις:** Κάθε δέντρο στο δάσος κάνει τις δικές του προβλέψεις ανεξάρτητα από τα υπόλοιπα.
- **Χρήση τυχαίων υποσυνόλων δεδομένων:** Κάθε δέντρο εκπαιδεύεται χρησιμοποιώντας τυχαία δείγματα και χαρακτηριστικά, ώστε να μειώνονται τα σφάλματα και η υπερεκπαίδευση.
- **Απαιτείται επαρκής όγκος δεδομένων:** Η διαθεσιμότητα αρκετών δεδομένων επιτρέπει στα δέντρα να διαφέρουν μεταξύ τους και να μαθαίνουν διαφορετικά μοτίβα.
- **Οι διαφορετικές προβλέψεις βελτιώνουν την ακρίβεια:** Ο συνδυασμός των προβλέψεων από πολλά διαφορετικά δέντρα οδηγεί σε πιο ακριβές τελικό αποτέλεσμα.



Σχήμα 4.1: Λειτουργία Random Forest [44]

4.3 XGBoost - eXtreme Gradient Boosting

Το XGBoost είναι μία πιο εξελιγμένη έκδοση του Gradient Boosting συνδυάζει αδύναμα μοντέλα για να δημιουργήσει ένα ισχυρό μοντέλο. [19]

- Το XGBoost χρησιμοποιεί δέντρα αποφάσεων ως βασικούς μαθητευόμενους και τα συνδυάζει διαδοχικά για να βελτιώσει την απόδοση του μοντέλου. Κάθε νέο δέντρο εκπαιδεύεται για να διορθώνει τα σφάλματα που έγιναν από το προηγούμενο δέντρο και αυτή η διαδικασία ονομάζεται ενίσχυση (boosting).
- Έχει ενσωματωμένη παράλληλη επεξεργασία για την γρήγορη εκπαίδευση μοντέλων σε μεγάλα σύνολα δεδομένων. Το XGBoost υποστηρίζει επίσης προσαρμογές που επιτρέπουν στους χρήστες να προσαρμόζουν τις παραμέτρους του μοντέλου για να βελτιστοποιούν την απόδοση με βάση το συγκεκριμένο πρόβλημα.

4.3.1 Πώς Λειτουργεί το XGBoost

Το XGBoost δημιουργεί δέντρα αποφάσεων διαδοχικά, με κάθε νέο δέντρο να προσπαθεί να διορθώσει τα σφάλματα του προηγούμενου. Η διαδικασία αναλύεται στα εξής βήματα:

1. **Έναρξη με ένα βασικό μοντέλο:** Το πρώτο δέντρο εκπαιδεύεται στα αρχικά δεδομένα. Στην περίπτωση παλινδρόμησης, το μοντέλο αυτό προβλέπει απλώς τον μέσο όρο της εξαρτημένης μεταβλητής.
2. **Υπολογισμός σφαλμάτων:** Μετά την πρώτη πρόβλεψη, υπολογίζεται η διαφορά (σφάλματα) μεταξύ των προβλεπόμενων και των πραγματικών τιμών.
3. **Εκπαίδευση επόμενου δέντρου:** Το επόμενο δέντρο εκπαιδεύεται πάνω στα σφάλματα του προηγούμενου, προσπαθώντας να τα διορθώσει.

4. **Επανάληψη διαδικασίας:** Η διαδικασία επαναλαμβάνεται, με κάθε νέο δέντρο να μαθαίνει από τα σφάλματα των προηγούμενων, μέχρι να ικανοποιηθεί κάποιο κριτήριο τερματισμού (π.χ. αριθμός δέντρων ή ελάχιστο σφάλμα).
5. **Συνδυασμός προβλέψεων:** Η τελική πρόβλεψη είναι το άθροισμα των προβλέψεων από όλα τα δέντρα του μοντέλου. Του οποίου ο τύπος είναι:

$$\hat{y}_i = \sum_{k=1}^K f_k(x_i), \quad f_k \in \mathcal{F}$$

όπου

- $\hat{y}_i$ είναι η τελική πρόβλεψη για το δείγμα i
- f_k το k -οστό δέντρο
- $\mathcal{F}$ ο χώρος όλων των δυνατών δέντρων απόφασης.

4.4 Logistic Regression

Το Logistic Regression είναι ένας επιβλεπόμενος αλγόριθμος μηχανικής μάθησης που χρησιμοποιείται για προβλήματα ταξινόμησης. Σε αντίθεση με τη Linear Regression που προβλέπει συνεχείς τιμές, προβλέπει την πιθανότητα μια είσοδος να ανήκει σε μια συγκεκριμένη κλάση. Χρησιμοποιείται για δυαδική ταξινόμηση όπου η έξοδος μπορεί να είναι μία από τις δύο πιθανές κατηγορίες, όπως Ναι/Όχι, Σωστό/Λάθος ή 0/1. Χρησιμοποιεί σιγμοειδή συνάρτηση (sigmoid) για να μετατρέψει τις εισόδους σε μια τιμή πιθανότητας μεταξύ 0 και 1. [21]

4.4.1 Τύποι Logistic Regression

Η λογιστική παλινδρόμηση διακρίνεται σε τρεις βασικούς τύπους, ανάλογα με τη φύση της εξαρτημένης μεταβλητής:

1. **Binomial Logistic Regression:** Χρησιμοποιείται όταν η εξαρτημένη μεταβλητή έχει μόνο δύο δυνατές κατηγορίες. Παραδείγματα: Ναι/Όχι, Επιτυχία/Αποτυχία, ή 0/1. Είναι η πιο κοινή μορφή και εφαρμόζεται σε προβλήματα δυαδικής ταξινόμησης.
2. **Multinomial Logistic Regression:** Χρησιμοποιείται όταν η εξαρτημένη μεταβλητή έχει τρεις ή περισσότερες κατηγορίες χωρίς φυσική σειρά. Παράδειγμα: ταξινόμηση ζώων σε "γάτα", "σκύλος", "πρόβατο". Επεκτείνει τη δυαδική λογιστική παλινδρόμηση ώστε να χειρίζεται πολλαπλές κλάσεις.
3. **Ordinal Logistic Regression:** Εφαρμόζεται όταν η εξαρτημένη μεταβλητή έχει τρεις ή περισσότερες κατηγορίες με φυσική σειρά ή ιεραρχία. Παραδείγματα: αξιολογήσεις όπως "χαμηλό", "μεσαίο", "υψηλό". Λαμβάνει υπόψη τη σειρά των κατηγοριών κατά τη μοντελοποίηση.

4.4.2 Πως λειτουργεί το Logistic Regression

Το Logistic Regression είναι ένα μοντέλο που χρησιμοποιείται για δυαδική ταξινόμηση. Μετασχηματίζει την έξοδο του Linear Regression σε πιθανότητα που κυμαίνεται μεταξύ 0 και 1, μέσω της συνάρτησης sigmoid.

Έστω ότι έχουμε n παρατηρήσεις και m χαρακτηριστικά. Η είσοδος περιγράφεται από τον πίνακα χαρακτηριστικών:

$$X = \begin{bmatrix} x_{11} & \cdots & x_{1m} \\ x_{21} & \cdots & x_{2m} \\ \vdots & \ddots & \vdots \\ x_{n1} & \cdots & x_{nm} \end{bmatrix}, \quad Y = \begin{cases} 0 & \text{αν ανήκει στην Κλάση 1} \\ 1 & \text{αν ανήκει στην Κλάση 2} \end{cases}$$

Εφαρμόζουμε τη γραμμική συνάρτηση:

$$z = w \cdot x + b = \sum_{i=1}^m w_i x_i + b$$

όπου $w = [w_1, w_2, \dots, w_m]$ είναι τα βάρη (weights) και b η σταθερά (bias).

Συνάρτηση Sigmoid

Για τη μετατροπή της εξόδου z σε πιθανότητα p , χρησιμοποιούμε τη συνάρτηση σιγμοειδ:

$$\sigma(z) = \frac{1}{1 + e^{-z}}$$

Άρα η πιθανότητα να ανήκει η παρατήρηση στην Κλάση 1 είναι:

$$P(y = 1 | x) = \sigma(w \cdot x + b) = \frac{1}{1 + e^{-(w \cdot x + b)}}$$

και επομένως:

$$P(y = 0 | x) = 1 - \sigma(w \cdot x + b)$$

Odds και Logit

Το odds ορίζεται ως:

$$\frac{p(x)}{1 - p(x)} = e^{w \cdot x + b}$$

και παίρνοντας τον φυσικό λογάριθμο έχουμε το logit:

$$\log \left(\frac{p(x)}{1 - p(x)} \right) = w \cdot x + b$$

Συνάρτηση Πιθανοφάνειας

Για ένα σύνολο n παρατηρήσεων, η συνάρτηση πιθανοφάνειας είναι:

$$L(w, b) = \prod_{i=1}^n [p(x_i)^{y_i} (1 - p(x_i))^{1-y_i}]$$

και το λογάριθμο της πιθανοφάνειας (log-likelihood) γίνεται:

$$\log L(w, b) = \sum_{i=1}^n [y_i \log p(x_i) + (1 - y_i) \log(1 - p(x_i))]$$

Με αντικατάσταση $p(x_i) = \sigma(w \cdot x_i + b)$, παίρνουμε:

$$\log L(w, b) = \sum_{i=1}^n [y_i(w \cdot x_i + b) - \log(1 + e^{w \cdot x_i + b})]$$

Βελτιστοποίηση μέσω Gradient Ascent

Για τη μεγιστοποίηση της log-likelihood χρησιμοποιούμε gradient ascent. Η μερική παράγωγος της log-likelihood ως προς κάθε βάρος w_j είναι:

$$\frac{\partial \log L(w, b)}{\partial w_j} = \sum_{i=1}^n (y_i - \sigma(w \cdot x_i + b)) x_{ij}$$

Αντίστοιχα, η παράγωγος ως προς το b είναι:

$$\frac{\partial \log L(w, b)}{\partial b} = \sum_{i=1}^n (y_i - \sigma(w \cdot x_i + b))$$


Οι παραπάνω εξισώσεις χρησιμοποιούνται στον αλγόριθμο gradient ascent ή σε παραλλαγές όπως stochastic ή mini-batch gradient ascent, για να εκπαιδευτεί το μοντέλο.

Τελική Μορφή του Μοντέλου

Η τελική εξίσωση της λογιστικής παλινδρόμησης είναι:

$$p(X; w, b) = \frac{1}{1 + e^{-(w \cdot X + b)}}$$

η οποία δίνει την πιθανότητα μια είσοδος X να ανήκει στην Κλάση 1.



Σχήμα 4.2: Διάγραμμα Logistic Regression [46]

4.5 LightGBM - Light Gradient Boosting Machine

Το LightGBM είναι ένα ανοικτού κώδικα, υψηλής απόδοσης πλαίσιο μηχανικής μάθησης που αναπτύχθηκε από τη Microsoft. Πρόκειται για ένα σύστημα ensemble learning που βασίζεται στη μέθοδο gradient boosting, κατά την οποία διαδοχικοί αδύναμοι μαθητές (weak learners), συνήθως δέντρα αποφάσεων, προστίθενται σταδιακά ώστε να κατασκευάσουν έναν ισχυρό τελικό μοντέλο, ακολουθώντας μια διαδικασία παρόμοια με την καθοδική κατηφορική πορεία (gradient descent).

Το LightGBM είναι σχεδιασμένο για αποδοτικότητα, κλιμακωσιμότητα και υψηλή ακρίβεια, ιδιαίτερα σε περιπτώσεις με μεγάλα σύνολα δεδομένων. Χρησιμοποιεί δέντρα αποφάσεων τα οποία αναπτύσσονται με αποδοτικό τρόπο ώστε να ελαχιστοποιείται η χρήση μνήμης και να επιταχύνεται ο χρόνος εκπαίδευσης. [16]

Ορισμένες από τις βασικές καινοτομίες του LightGBM περιλαμβάνουν:

- **Gradient-based One-Side Sampling (GOSS):** Επιλέγει τα δείγματα με τις μεγαλύτερες κλίσεις (gradients) για εκπαίδευση, μειώνοντας τον αριθμό των δειγμάτων χωρίς να θυσιάζει την ακρίβεια.
- **Histogram-based algorithms:** Τα συνεχόμενα χαρακτηριστικά μετατρέπονται σε διακριτά βινς, μειώνοντας σημαντικά την πολυπλοκότητα και την κατανάλωση μνήμης.

- **Leaf-wise tree growth:** Αντί να αναπτύσσει τα δέντρα επίπεδο προς επίπεδο (level-wise), όπως άλλες μέθοδοι, το LightGBM επιλέγει να αναπτύσσει το φύλλο που προσφέρει τη μεγαλύτερη μείωση του σφάλματος, οδηγώντας σε καλύτερη ακρίβεια με λιγότερους πόρους.
- **Gradient Boosting Decision Trees (GBDT):** Δημιουργεί δέντρα αποφάσεων διαδοχικά για να διορθώνει σφάλματα επαναληπτικά.

4.5.1 Κύριες Παράμετροι του LightGBM

Η απόδοση του LightGBM επηρεάζεται σημαντικά από τις βασικές παραμέτρους που καθορίζουν τη δομή και τη διαδικασία βελτιστοποίησης του μοντέλου. Παρακάτω παρουσιάζονται ορισμένες από τις σημαντικότερες παραμέτρους:

- **objective:** Καθορίζει τη συνάρτηση απώλειας που βελτιστοποιείται κατά την εκπαίδευση. Το LightGBM υποστηρίζει πολλαπλούς τύπους στόχων όπως regression, binary classification και multiclass classification.
- **task:** Καθορίζει το είδος της διαδικασίας που επιθυμούμε, είτε train είτε prediction. Η προεπιλεγμένη τιμή είναι train.
- **num_leaves:** Ορίζει τον μέγιστο αριθμό φύλλων σε κάθε δέντρο. Υψηλότερες τιμές επιτρέπουν στο μοντέλο να συλλάβει πιο πολύπλοκα μοτίβα, αλλά μπορεί να οδηγήσουν σε υπερεκπαίδευση (overfitting).
- **learning_rate:** Καθορίζει το μέγεθος του βήματος σε κάθε επανάληψη της κατωδικής κατηφορικής πορείας (gradient descent). Μικρότερες τιμές οδηγούν σε πιο αργή εκπαίδευση, αλλά πιθανώς βελτιώνουν τη γενίκευση του μοντέλου.
- **max_depth:** Ορίζει το μέγιστο βάθος των δέντρων. Χρήσιμο για τον περιορισμό της πολυπλοκότητας και την αποφυγή υπερεκπαίδευσης.
- **min_data_in_leaf:** Ελάχιστος αριθμός δειγμάτων που απαιτείται για να σχηματιστεί ένας κόμβος-φύλλο. Υψηλότερες τιμές περιορίζουν την υπερεκπαίδευση αλλά μπορεί να οδηγήσουν σε υποεκπαίδευση.
- **num_iterations:** Ο αριθμός επαναλήψεων που θα εκτελεστούν κατά την εκπαίδευση. Η προεπιλεγμένη τιμή είναι 100.
- **feature_fraction:** Ποσοστό χαρακτηριστικών που θα επιλεγούν τυχαία για την κατασκευή κάθε δέντρου. Βοηθά στη μείωση της υπερεκπαίδευσης και ενισχύει τη γενίκευση.
- **bagging_fraction:** Ποσοστό των δειγμάτων που θα χρησιμοποιηθούν για εκπαίδευση μέσω bagging (δειγματοληψία με επανάθεση).

- **L1 και L2:** Παράμετροι κανονικοποίησης (regularization) που ελέγχουν αντίστοιχα την L1 και L2 ποινή. Επιβάλλουν ποινές στους μεγάλους συντελεστές και μειώνουν τον κίνδυνο υπερεκπαίδευσης.
- **min_split_gain:** Καθορίζει το ελάχιστο κέρδος πληροφορίας που απαιτείται για να διαχωριστεί περαιτέρω ένας κόμβος. Ελέγχει την ανάπτυξη του δέντρου και αποτρέπει περιττούς διαχωρισμούς.
- **categorical_feature:** Δηλώνει τα κατηγορικά χαρακτηριστικά που πρέπει να ληφθούν υπόψη κατά την εκπαίδευση. Το LightGBM έχει ενσωματωμένη υποστήριξη για κατηγορικά δεδομένα.

Χάρη σε αυτές τις τεχνικές, το LightGBM συχνά ξεπερνά άλλα αντίστοιχα συστήματα τόσο σε ταχύτητα όσο και σε ακρίβεια.

4.6 Τρόποι υπολογισμού επίδοσης μοντέλων

Η αξιολόγηση των μοντέλων πρόβλεψης σε προβλήματα πολυταξινόμησης (multi-class classification), όπως στην περίπτωση πρόβλεψης αποτελέσματος ποδοσφαιρικού αγώνα με τις κατηγορίες Νίκη, Ισοπαλία και Ήττα, απαιτεί ειδικές μετρικές που να λαμβάνουν υπόψη όλες τις κλάσεις.

Οι βασικές μετρικές αξιολόγησης που χρησιμοποιούνται είναι οι εξής:

- **Accuracy:** Το ποσοστό των σωστά προβλεφθέντων δειγμάτων σε σχέση με το σύνολο. Υπολογίζεται ως:

$$\text{Accuracy} = \frac{\text{Αριθμός σωστών προβλέψεων}}{\text{Συνολικός αριθμός παραδειγμάτων}}$$

- **Precision:** Το ποσοστό των προβλέψεων για μια συγκεκριμένη κλάση που είναι σωστές. Για την κλάση νίκη, για παράδειγμα:

$$\text{Precision} = \frac{\text{True Positives}}{\text{True Positives} + \text{False Positives}}$$

- **Recall:** Το ποσοστό των πραγματικών δειγμάτων μιας κλάσης που εντοπίστηκαν σωστά από το μοντέλο:

$$\text{Recall} = \frac{\text{True Positives}}{\text{True Positives} + \text{False Negatives}}$$

- **F1-Score:** Ο αρμονικός μέσος των Precision και Recall για κάθε κλάση:

$$F1 = 2 \cdot \frac{\text{Precision} \cdot \text{Recall}}{\text{Precision} + \text{Recall}}$$

- **Support:** Ο αριθμός των πραγματικών παραδειγμάτων που ανήκουν σε κάθε κλάση στο δατασετ. Δεν αποτελεί απόδοση, αλλά βοηθά στην ερμηνεία των μετρικών.

- **Macro Average:** Ο μέσος όρος Precision, Recall και F1 όλων των κλάσεων, χωρίς στάθμιση με βάση το πλήθος δειγμάτων (support). Αντιμετωπίζει όλες τις κλάσεις εξίσου, ακόμα κι αν είναι άνισα κατανομημένες.
- **Weighted Average:** Ο μέσος όρος Precision, Recall και F1 όλων των κλάσεων, αλλά σταθμισμένος ανάλογα με το support (δηλαδή την αναλογία των κλάσεων στο σύνολο των δεδομένων). Είναι πιο αντιπροσωπευτικό όταν υπάρχει ανισορροπία μεταξύ των κατηγοριών.
- **Confusion Matrix (Πίνακας Σύγχυσης):** Ένας πίνακας 3×3 στην περίπτωση μας, που παρουσιάζει για κάθε πραγματική κλάση πόσα δείγματα ταξινομήθηκαν σε κάθε προβλεπόμενη κατηγορία. Η διαγώνιος αντιστοιχεί στις σωστές προβλέψεις, ενώ οι εκτός διαγωνίου τιμές δείχνουν τα λάθη.

Οι παραπάνω μετρικές επιτρέπουν την πλήρη αξιολόγηση της συμπεριφοράς των ταξινομητικών μοντέλων τόσο σε συνολικό επίπεδο (accuracy, macro/weighted avg), όσο και σε επίπεδο κάθε κατηγορίας χωριστά (per-class precision, recall, f1). Αυτό είναι ιδιαίτερα σημαντικό όταν υπάρχει ασυμμετρία στην κατανομή των αποτελεσμάτων (π.χ. πιο συχνές οι ήττες ή οι νίκες σε σχέση με τις ισοπαλίες).

Κεφάλαιο 5

Περιγραφή των Δεδομένων

Σε αυτό το κεφάλαιο περιγράφεται αναλυτικά το σύνολο δεδομένων (dataset) που χρησιμοποιήθηκε στο πλαίσιο της διπλωματικής εργασίας. Παρουσιάζονται η πηγή των δεδομένων, οι ενέργειες επεξεργασίας που πραγματοποιήθηκαν για την καλύτερη αξιοποίησή τους, καθώς και η ερμηνεία των μεταβλητών που περιέχονται στο αρχείο. Ο σκοπός της ανάλυσης είναι να αναδειχθεί η χρησιμότητα των επιμέρους χαρακτηριστικών για την πρόβλεψη ποδοσφαιρικών αποτελεσμάτων μέσω τεχνικών μηχανικής μάθησης.

5.1 Πηγή Δεδομένων

Η πηγή των δεδομένων είναι το διαδικτυακό αποθετήριο Kaggle, το οποίο αποτελεί μια από τις μεγαλύτερες πλατφόρμες διαμοιρασμού συνόλων δεδομένων για ερευνητικούς σκοπούς. Το συγκεκριμένο dataset περιέχει στοιχεία για όλους τους αγώνες του αγγλικού πρωταθλήματος ποδοσφαίρου πρώτης κατηγορίας (Premier League) για τις αγωνιστικές περιόδους 2019–2020 έως και 2023–2024 [32]. Τα δεδομένα είναι οργανωμένα σε αρχείο μορφής CSV, επιτρέποντας εύκολη φόρτωση και επεξεργασία μέσω βιβλιοθηκών ανάλυσης δεδομένων.

Η αξιοπιστία της πηγής είναι σημαντική, καθώς εξασφαλίζει την εγκυρότητα και την πληρότητα του συνόλου δεδομένων. Επιπλέον, η μορφοποίηση του αρχείου διευκολύνει τη χρήση του στο περιβάλλον που αναπτύχθηκε το παρόν σύστημα, το οποίο βασίζεται σε PySpark, Tkinter GUI και μοντέλα μηχανικής μάθησης.

5.2 Επεξεργασία Συνόλου Δεδομένων

Πριν ξεκινήσει η φάση της ανάλυσης και της εκπαίδευσης των μοντέλων, κρίθηκε απαραίτητο να γίνουν παρεμβάσεις καθαρισμού και κανονικοποίησης των δεδομένων, ώστε να διασφαλιστεί η συνέπεια και η ποιότητα των εισόδων στο σύστημα.

5.2.1 Συντομογραφίες Ομάδων

Σε πολλές περιπτώσεις, τα ονόματα των ομάδων ήταν γραμμένα με συντομογραφίες ή διαφορετικούς τρόπους (π.χ. “Man Utd” αντί για “Manchester United”). Προκειμένου να

υπάρχει ομοιομορφία σε όλο το dataset και να λειτουργούν σωστά οι μηχανισμοί αναγνώρισης και σύγκρισης ομάδων, τα ονόματα αυτά τροποποιήθηκαν χειροκίνητα.

5.2.2 Αφαίρεση Διπλότυπων Εγγραφών

Εντοπίστηκαν εγγραφές που αφορούσαν το ίδιο παιχνίδι δύο φορές — μία για κάθε ομάδα, με σχεδόν πανομοιότυπα δεδομένα. Για την αποφυγή υπερβολικής πληροφορίας και επαναλήψεων, αφαιρέθηκε η μία από τις δύο εγγραφές κάθε τέτοιας περίπτωσης. Αυτό έγινε επίσης χειροκίνητα, καθώς η διατήρηση και των δύο απαιτούσε πολύπλοκη λογική και αύξανε σημαντικά τον χρόνο εκπαίδευσης των μοντέλων χωρίς αντίστοιχο όφελος.

5.3 Επεξήγηση Μεταβλητών

Το αρχείο δεδομένων περιλαμβάνει 28 στήλες (μεταβλητές), οι οποίες περιέχουν πληροφορίες τόσο για την ταυτότητα του αγώνα όσο και για στατιστικά που προκύπτουν κατά τη διάρκειά του. Δεν χρησιμοποιήθηκαν όλες οι μεταβλητές στη διαδικασία πρόβλεψης, καθώς αρκετές κρίθηκαν μη σχετικές ή πλεονάζουσες. Ακολουθεί παρουσίαση και ερμηνεία των σημαντικότερων μεταβλητών.

5.3.1 Ημερομηνία και Ώρα Αγώνα

Οι στήλες Date και Time καταγράφουν την ημερομηνία και την ώρα διεξαγωγής κάθε αγώνα. Είναι σημαντικές καθώς πολλές από τις διαδικασίες εξαγωγής χαρακτηριστικών βασίζονται σε χρονικές σχέσεις (π.χ. αγώνες τελευταίας πεντάδας, πρόσφατη φόρμα ομάδων κ.λπ.). Υπάρχει επίσης η στήλη Day, η οποία αναφέρει τη μέρα της εβδομάδας, αλλά δεν χρησιμοποιήθηκε στην παρούσα εργασία, καθώς κρίθηκε λιγότερο σχετική.

5.3.2 Διοργάνωση και Αγωνιστική Περίοδος

Οι στήλες comp (διοργάνωση), season (αγωνιστική περίοδος) και round (αγωνιστική) είναι διαθέσιμες, ωστόσο δεν χρησιμοποιήθηκαν όλες. Επειδή το dataset περιλαμβάνει αποκλειστικά αγώνες της Premier League, η στήλη comp είναι περιττή. Ομοίως, η αγωνιστική μπορεί να υπολογιστεί περίπου βάσει ημερομηνίας.

5.3.3 Έδρα

Η στήλη venue αναφέρει αν η ομάδα είναι γηπεδούχος (Home) ή φιλοξενούμενη (Away). Η πληροφορία αυτή είναι κρίσιμη, καθώς επηρεάζει σημαντικά τα στατιστικά των ομάδων και έχει αποδειχθεί ότι η έδρα παίζει ρόλο στην έκβαση των αγώνων.

5.3.4 Τελικό Αποτέλεσμα και Γκολ

Η τελική έκβαση του αγώνα περιγράφεται μέσα από τις στήλες με το τελικό σκορ, τα συνολικά γκολ υπέρ και κατά. Οι πληροφορίες αυτές αποτελούν τη «στόχευση» (target) στην

πρόβλεψη αποτελέσματος και άρα είναι απολύτως απαραίτητες στην εργασία.

Expected Goals – xG Ο δείκτης Expected Goals (xG) είναι από τους πιο σύγχρονους και ακριβείς τρόπους να μετρηθεί η ποιότητα των ευκαιριών σκοραρίσματος. Το xG αποδίδει μία αριθμητική τιμή στην πιθανότητα ένα συγκεκριμένο σουτ να οδηγήσει σε γκολ, με βάση πλήθος παραγόντων, όπως:

- Η απόσταση και η γωνία εκτέλεσης του σουτ.
- Ο τρόπος εκτέλεσης (σουτ με το πόδι ή κεφαλιά).
- Αν το σουτ προέρχεται από οργανωμένη προσπάθεια, αντεπίθεση ή στατική φάση.
- Η θέση και κατάσταση του παίκτη πριν το σουτ.

Η τιμή του xG είναι πολύτιμη για να μετρηθεί η επιθετική αποδοτικότητα μιας ομάδας ανεξαρτήτως του πραγματικού σκορ.

Expected Goals Against – xGA Το xGA είναι ο αντίστοιχος δείκτης για τις ευκαιρίες που επιτρέπει η άμυνα μιας ομάδας στον αντίπαλο. Όσο υψηλότερη η τιμή του, τόσο πιο «εύκολα» φτάνει ο αντίπαλος σε πιθανότητες σκοραρίσματος. Συνεπώς, αποτελεί ένδειξη αμυντικής αδυναμίας.

5.3.5 Δεδομένα Σουτ

Το dataset περιλαμβάνει και πιο απλές μετρήσεις σουτ:

- sh: Συνολικά σουτ.
- sot: Σουτ εντός εστίας.
- dist: Μέση απόσταση εκτέλεσης.

Ωστόσο, λόγω της παρουσίας του xG, τα παραπάνω δεν χρησιμοποιήθηκαν άμεσα, αφού το xG περιλαμβάνει πιο ποιοτική και πολυδιάστατη πληροφορία.

5.3.6 Στατικές Φάσεις

Οι στήλες fk (ελεύθερα φάουλ), pkatt (πέναλτι που κερδήθηκαν), pk (πέναλτι συνολικά) περιέχουν πληροφορίες σχετικές με στατικές ευκαιρίες. Αν και παρουσιάζουν ενδιαφέρον, δεν χρησιμοποιήθηκαν στο βασικό μοντέλο λόγω έλλειψης συνέπειας ή επαρκούς συνδυαστικής πληροφορίας με άλλα χαρακτηριστικά.

5.3.7 Σύστημα Ομάδας

Η στήλη formation περιέχει το αρχικό σύστημα της ομάδας (π.χ. 4-3-3, 4-2-3-1). Η πληροφορία αυτή χρησιμοποιείται στο πλαίσιο της εργασίας, καθώς αποτελεί ένδειξη του αγωνιστικού στυλ και της προσέγγισης του κάθε συλλόγου.

5.3.8 Ομάδα και Αντίπαλος

Κάθε γραμμή περιγράφει έναν αγώνα από την οπτική μίας μόνο ομάδας, με τη στήλη team να περιέχει την ομάδα που εξετάζεται και τη opponent τον αντίπαλό της. Υπάρχει αντίστοιχη εγγραφή και για την άλλη ομάδα, οπότε τα δεδομένα είναι πλήρη και για τις δύο πλευρές κάθε αναμέτρησης.

5.3.9 Λοιπά Στοιχεία

Το αρχείο περιέχει και άλλες πληροφορίες, όπως ο διαιτητής (referee), ο αρχηγός ομάδας (captain), το πλήθος θεατών (attendance), καθώς και διάφορα σχόλια/σημειώσεις που είναι κατά κύριο λόγο κενές. Οι πληροφορίες αυτές δεν χρησιμοποιήθηκαν, καθώς είτε είναι ασήμαντες για τον σκοπό της εργασίας είτε απουσιάζουν συστηματικά.

Κεφάλαιο 6

Εργαλεία που χρησιμοποιήθηκαν

Παρακάτω αναλύονται εργαλεία που χρησιμοποιήθηκαν για την επίτευξη της εργασίας

6.1 Python

Η Python είναι μια γλώσσα προγραμματισμού υπολογιστών που χρησιμοποιείται συχνά για την κατασκευή ιστότοπων και λογισμικού, την αυτοματοποίηση εργασιών και την ανάλυση δεδομένων. Η Python είναι μια γλώσσα γενικού σκοπού, που σημαίνει ότι μπορεί να χρησιμοποιηθεί για τη δημιουργία μιας ποικιλίας διαφορετικών προγραμμάτων και δεν είναι εξειδικευμένη για συγκεκριμένα προβλήματα. Για αυτό λόγω της ευελιξίας της και της ευκολία της χρησιμοποιήθηκε και στην συγκεκριμένη διπλωματική εργασία.

Χρησιμοποιήθηκαν και αρκετές βιβλιοθήκες της Python για την επίτευξη της εργασίας που αναφέρονται παρακάτω:

6.1.1 Numpy

Η Numpy είναι ένα πακέτο επεξεργασίας πινάκων γενικής χρήσης. Παρέχει ένα αντικείμενο πολυδιάστατων πινάκων υψηλής απόδοσης και εργαλεία για την εργασία με αυτούς τους πίνακες. Είναι το θεμελιώδες πακέτο για επιστημονικούς υπολογισμούς με την Python. Εκτός από τις προφανείς επιστημονικές χρήσεις του, το Numpy μπορεί επίσης να χρησιμοποιηθεί ως ένας αποδοτικός πολυδιάστατος περιέκτης γενικών δεδομένων.

6.1.2 Scikit-Learn

Το Scikit-learn, μια βιβλιοθήκη Python ανοιχτού κώδικα (open-source), βοηθά στην προσαρμοστικότητα της μηχανικής μάθησης. Παρέχει μια απλή, συνεπή διεπαφή για μια ποικιλία εργασιών όπως ταξινόμηση (classification), παλινδρόμηση (regression), ομαδοποίηση (clustering), προεπεξεργασία δεδομένων και αξιολόγηση μοντέλων. Περιέχει έτοιμα μοντέλα

Η βιβλιοθήκη Scikit-learn χρησιμοποιείται διότι καθιστά την κατασκευή μοντέλων μηχανικής μάθησης απλή και αποδοτική. Παρακάτω παρατίθενται οι βασικοί λόγοι για την επιλογή της: [25]

- **Έτοιμα Εργαλεία:** Παρέχει ενσωματωμένες συναρτήσεις για κοινές εργασίες όπως προεπεξεργασία δεδομένων, εκπαίδευση μοντέλων και παραγωγή προβλέψεων. Έτσι, εξοικονομείται χρόνος αφού αποφεύγεται η ανάγκη υλοποίησης αλγορίθμων από το μηδέν.
- **Εύκολη Αξιολόγηση Μοντέλων:** Περιλαμβάνει εργαλεία όπως η διασταυρούμενη επικύρωση (cross-validation) και διάφορους δείκτες απόδοσης, επιτρέποντας την ακριβή εκτίμηση της ποιότητας του μοντέλου και την εντόπιση πιθανών αδυναμιών.
- **Πλούσια Υποστήριξη Αλγορίθμων:** Υποστηρίζει πλήθος δημοφιλών αλγορίθμων μηχανικής μάθησης για προβλήματα ταξινόμησης, παλινδρόμησης και ομαδοποίησης, προσφέροντας ευελιξία στην επιλογή κατάλληλου μοντέλου.
- **Ομαλή Ενσωμάτωση:** Είναι χτισμένη πάνω σε θεμελιώδεις βιβλιοθήκες της Πύλης όπως οι NumPy και SciPy, γεγονός που διευκολύνει την ενσωμάτωσή της σε υπάρχουσες ροές εργασίας ανάλυσης δεδομένων.
- **Απλή και Συνεπής Διεπαφή:** Η κοινή σύνταξη που χρησιμοποιείται σε διαφορετικούς αλγορίθμους καθιστά ευκολότερη την εκμάθηση και τη μετάβαση μεταξύ μοντέλων.
- **Εύκολη Βελτιστοποίηση Μοντέλου:** Εργαλεία όπως το GridSearchCV επιτρέπουν τη ρύθμιση υπερπαραμέτρων με σκοπό τη βελτίωση της ακρίβειας του μοντέλου χωρίς επιπλέον πολυπλοκότητα.

6.1.3 Matplotlib

Το Matplotlib είναι μια βιβλιοθήκη οπτικοποίησης ανοιχτού κώδικα για τη γλώσσα προγραμματισμού Python, η οποία χρησιμοποιείται ευρέως για τη δημιουργία στατικών, κινούμενων και διαδραστικών γραφημάτων. Παρέχει ένα αντικειμενοστρεφές API για την ενσωμάτωση γραφημάτων σε εφαρμογές χρησιμοποιώντας εργαλεία GUI γενικής χρήσης όπως Tkinter, Qt, GTK και wxPython. Προσφέρει μια ποικιλία λειτουργιών σχεδίασης, όπως γραφήματα γραμμών, γραφήματα ράβδων, ιστογράμματα, γραφήματα διασποράς και τρισδιάστατες απεικονίσεις.

6.1.4 Tkinter

Το Python Tkinter είναι μια τυπική βιβλιοθήκη GUI για Python, η οποία παρέχει έναν γρήγορο και εύκολο τρόπο δημιουργίας εφαρμογών επιφάνειας εργασίας. Το Tkinter παρέχει μια ποικιλία γραφικών στοιχείων όπως κουμπιά, ετικέτες, πλαίσια κειμένου, μενού και άλλα που μπορούν να χρησιμοποιηθούν για τη δημιουργία διαδραστικών διεπαφών χρήστη. Το Tkinter υποστηρίζει προγραμματισμό βάσει συμβάντων (event-driving), όπου οι ενέργειες πραγματοποιούνται ως απόκριση σε συμβάντα χρήστη, όπως κλικ ή πάτημα πλήκτρων.

6.1.5 PySpark

Το Apache Spark είναι μια ισχυρή open-source μηχανή επεξεργασίας δεδομένων, γραμμένη σε Scala, σχεδιασμένη για επεξεργασία δεδομένων μεγάλης κλίμακας. Για την υποστήριξη της γλώσσας Python, η κοινότητα του Apache Spark ανέπτυξε το εργαλείο PySpark. Με τη χρήση του PySpark, είναι δυνατή η εργασία με RDDs (Resilient Distributed Datasets) και στην Python. Αυτό καθίσταται εφικτό μέσω της βιβλιοθήκης Py4J, η οποία επιτρέπει τη διασύνδεση μεταξύ Python και Java.

Το PySpark είναι το Python API για το Apache Spark. Επιτρέπει τη διασύνδεση με το κατανεμημένο υπολογιστικό πλαίσιο του Spark χρησιμοποιώντας τη γλώσσα Python, καθιστώντας ευκολότερη την εργασία με μεγάλα δεδομένα για επιστήμονες και μηχανικούς δεδομένων που είναι εξοικειωμένοι με την Python. Μέσω του PySpark, μπορούμε να δημιουργούμε και να διαχειριζόμαστε εργασίες Spark, καθώς και να πραγματοποιούμε πολύπλοκους μετασχηματισμούς και αναλύσεις δεδομένων.

6.1.6 Pytorch

Το PyTorch είναι μια βιβλιοθήκη βαθιάς μάθησης που βασίζεται σε Python και Torch (ένα Lua-based framework). Παρέχει επιτάχυνση GPU, δυναμικά γραφήματα υπολογισμού και μια διαισθητική διεπαφή για ερευνητές και προγραμματιστές βαθιάς μάθησης. Το PyTorch ακολουθεί μια προσέγγιση "ορισμός-ανά-εκτέλεση", που σημαίνει ότι τα υπολογιστικά του γραφήματα κατασκευάζονται εν κινήσει, επιτρέποντας καλύτερη αποσφαλμάτωση και προσαρμογή μοντέλου.

Κύρια Χαρακτηριστικά του PyTorch

Η βιβλιοθήκη PyTorch προσφέρει σύγχρονα εργαλεία και μεγάλη ευελιξία για την ανάπτυξη μοντέλων βαθιάς μάθησης. Παρακάτω παρουσιάζονται ορισμένα από τα βασικά της χαρακτηριστικά:

- **Δυναμικά Γραφήματα Υπολογισμού (Dynamic Computational Graphs):** Το PyTorch δημιουργεί γραφήματα υπολογισμού δυναμικά κατά την εκτέλεση. Αυτό επιτρέπει μεγαλύτερη ευελιξία στον σχεδιασμό, την επεξεργασία και την αποσφαλμάτωση (debugging) μοντέλων σε πραγματικό χρόνο.
- **Αυτόματη Παραγωγή Παραγώγων (Autograd):** Ενσωματώνει έναν ισχυρό μηχανισμό αυτόματης διαφοροποίησης, ο οποίος διευκολύνει σημαντικά τον υπολογισμό παραγώγων για τη διαδικασία της οπισθοδιάδοσης (backpropagation) στα νευρωνικά δίκτυα.
- **Υποστήριξη για CUDA:** Το PyTorch υποστηρίζει χρήση GPU μέσω CUDA της NVIDIA, επιτρέποντας την ταχύτατη εκτέλεση υπολογισμών και την επιτάχυνση της εκπαίδευσης νευρωνικών δικτύων.

6.1.7 Queue

Όπως μια στοίβα, η ουρά είναι μια γραμμική δομή δεδομένων που αποθηκεύει στοιχεία με τρόπο FIFO (First In First Out). Με μια ουρά, το στοιχείο που προστέθηκε λιγότερο πρόσφατα αφαιρείται πρώτο. Ένα καλό παράδειγμα ουράς είναι οποιαδήποτε ουρά consumer για έναν πόρο όπου ο consumer που ήρθε πρώτος εξυπηρετείται πρώτος.

6.1.8 Threading

Το Multithreading ορίζεται ως η ικανότητα ενός επεξεργαστή να εκτελεί πολλαπλά νήματα (threads) ταυτόχρονα. Σε έναν απλό επεξεργαστή με έναν μόνο πυρήνα (single-core CPU), αυτό επιτυγχάνεται μέσω της συχνής εναλλαγής μεταξύ των νημάτων. Η διαδικασία αυτή ονομάζεται context switching.

Κατά το context switching, η κατάσταση (state) του τρέχοντος νήματος αποθηκεύεται και φορτώνεται η κατάσταση ενός άλλου νήματος, κάθε φορά που συμβαίνει κάποια διακοπή, είτε λόγω εισόδου/εξόδου (I/O), είτε από κάποια προγραμματισμένη ενέργεια. Αυτή η εναλλαγή συμβαίνει τόσο συχνά, ώστε όλα τα νήματα φαίνεται να εκτελούνται ταυτόχρονα. Η ψευδαίσθηση αυτή της ταυτόχρονης εκτέλεσης ονομάζεται multitasking.

6.1.9 functools

Η ενότητα functools προσφέρει μια συλλογή εργαλείων που απλοποιούν την εργασία με συναρτήσεις και αντικείμενα που μπορούν να κληθούν. Περιλαμβάνει βοηθητικά προγράμματα για την τροποποίηση, επέκταση ή βελτιστοποίηση συναρτήσεων χωρίς να ξαναγραφεί η βασική τους λογική, βοηθώντας σας να γράφετε καθαρότερο και πιο αποτελεσματικό κώδικα.

lru_cache

Το lru_cache αποθηκεύει προσωρινά τα πρόσφατα αποτελέσματα συναρτήσεων για να επιταχύνει τις επαναλαμβανόμενες κλήσεις με τα ίδια ορίσματα, βελτιώνοντας την απόδοση με κόστος τη μνήμη.

Κεφάλαιο 7

Υλοποίηση εργασίας

Με την ανάλυση των προηγούμενων κεφαλαίων κυρίως για το θεωρητικό υπόβαθρο της εργασίας θα γίνει μια περιγραφή του κώδικα για την υλοποίηση των μοντέλων πρόβλεψης.


7.1 Επεξεργασία δεδομένων

Έχοντας αναλυθεί η δομή του csv που χρησιμοποιείται σε προηγούμενο κεφάλαιο, τα δεδομένα τα προεπεξεργάζεται και τα εξάγει το Apache Spark. Η Spark διευκολύνει τη μαζική επεξεργασία των δεδομένων, επιτρέποντας γρήγορους μετασχηματισμούς. Προτιμήθηκε spark λόγω του μεγάλου όγκου αγωνιστικών δεδομένων και της ανάγκης για αποδοτική προεπεξεργασία και εξαγωγή χαρακτηριστικών (features) για κάθε αγώνα.

7.2 Χρήση GUI

Για την αλληλεπίδραση του χρήστη με το σύστημα, υλοποιήθηκε γραφικό περιβάλλον χρήστη (GUI) με χρήση της βιβλιοθήκης Tkinter. Μέσα από αυτό, ο χρήστης μπορεί να επιλέξει δύο ομάδες και να ζητήσει την πρόβλεψη αποτελέσματος του μεταξύ τους αγώνα. Η πρόβλεψη εμφανίζεται με τη μορφή πιθανοτήτων για τα τρία δυνατά αποτελέσματα: Νίκη Γηπεδούχου, Ισοπαλία, Νίκη Φιλοξενούμενου.

Η χρήση του GUI καθιστά το σύστημα πιο προσιτό και διευκολύνει τη διερεύνηση της ρεαλιστικότητας των προβλέψεων από πλευράς του χρήστη.



Σχήμα 7.1: Το gui στην διάρκεια της εκπαίδευσης

7.3 Εξαγωγή δεδομένων

Έχει δημιουργηθεί μια ξεχωριστή κλάση με το όνομα `SafeFeatureExtractor` η οποία έχει όλα τα features που χρειάζονται για την πρόβλεψη και περιέχονται τα εξής σύνολα χαρακτηριστικών, τα οποία εξάγονται από το ιστορικό δεδομένων των ομάδων και των αγώνων.

7.3.1 Φόρμα Ομάδας

Για κάθε ομάδα υπολογίζεται η αγωνιστική της φόρμα με βάση τους τελευταίους πέντε αγώνες. Συγκεκριμένα, υπολογίζονται τα εξής:

- Ποσοστά νικών, ισοπαλιών και ηττών.
- Μέσος όρος γκολ υπέρ ανά αγώνα.
- Μέσος όρος Expected Goals (xG) και Expected Goals Against (xGA).

Η παραπάνω διαδικασία εφαρμόζεται ξεχωριστά για αγώνες εντός και εκτός έδρας, προκειμένου να αποτυπωθούν πιθανές διαφορές απόδοσης της ομάδας ανάλογα με την έδρα.

7.3.2 Αντιμετώπιση Αντιπάλου Συστήματος

Για κάθε ομάδα εντοπίζεται ο πιο συχνά χρησιμοποιούμενος αρχικός σχηματισμός (formation) στους τελευταίους 20 αγώνες της. Παράλληλα, καταγράφονται οι σχηματισμοί που αντιμετώπισε η ομάδα στο ίδιο χρονικό διάστημα.

Στη συνέχεια, υπολογίζεται το ποσοστό νικών της ομάδας απέναντι στον δημοφιλέστερο σχηματισμό του αντιπάλου της. Αυτό το χαρακτηριστικό δίνει μία ένδειξη για το πώς αποδίδει η ομάδα απέναντι σε συγκεκριμένα αγωνιστικά συστήματα.

7.3.3 Power Ranking

Ο δείκτης Power Ranking δημιουργείται με βάση την συνολική απόδοση της ομάδας σε όλους τους αγώνες του dataset. Συγκεκριμένα, υπολογίζεται ο μέσος όρος βαθμών ανά αγώνα.

Αυτό το χαρακτηριστικό επιτρέπει στο μοντέλο να διαχωρίσει τη γενική δυναμικότητα των ομάδων, ακόμη και αν κάποια από αυτές βρίσκεται σε κακή αγωνιστική περίοδο, αλλά παραμένει ιστορικά ισχυρή.

7.3.4 Ιστορικό Προηγούμενων Αναμετρήσεων

Για κάθε ζεύγος ομάδων που πρόκειται να αγωνιστεί, καταγράφεται το ιστορικό αποτελεσμάτων των μεταξύ τους αναμετρήσεων. Από αυτό υπολογίζονται τα εξής ποσοστά:

- Ποσοστό νικών του γηπεδούχου.
- Ποσοστό ισοπαλιών.

- Ποσοστό νικών του φιλοξενούμενου.

Το χαρακτηριστικό αυτό παρέχει ιστορική προοπτική στην απόδοση των ομάδων μεταξύ τους και ενδέχεται να αποκαλύψει ψυχολογική ή τακτική υπεροχή της μιας πλευράς.

7.4 Εκπαίδευση μοντέλων

Για κάθε μοντέλο υπάρχει όπως είναι αναμενόμενο διαφορετικός τρόπος εκπαίδευσης βάσει του κώδικα. Το κοινό που έχουν όλα τα μοντέλα είναι ότι παίρνουν τα απαραίτητα δεδομένα για τα features απο την κλάση SafeFeatureExtractor και δημιουργούνται τρία labels για τα τρία πιθανά αποτελέσματα ενός ποδοσφαιρικού αγώνα (νίκη γηπεδούχου/ισοπαλία/νίκη φιλοξενούμενου).

7.4.1 Εκπαίδευση με MLP

Το Multilayer Perceptron (MLP) αποτελεί το βασικό νευρωνικό δίκτυο που χρησιμοποιήθηκε στην εργασία για την πρόβλεψη του αποτελέσματος ενός ποδοσφαιρικού αγώνα. Η αρχιτεκτονική του περιλαμβάνει είσοδο με πλήθος νευρώνων ίσο με τον αριθμό των χαρακτηριστικών (features) δηλαδή 28 στην περίπτωση μας. Για την καλύτερη κατανόηση σύνθετων σχέσεων των features χρησιμοποιήθηκαν τρία hidden layers με 128, 64 και 32 να είναι οι τιμές των κρυφών νευρώνων ανα επίπεδο. Χρησιμοποιήθηκε η συνάρτηση ενεργοποίησης ReLU για την καλύτερη εκμάθηση και το dropout για την κανονικοποίηση. Η έξοδος περιέχει τρεις νευρώνες που αντιστοιχούν στις πιθανότητες για νίκη γηπεδούχου, ισοπαλία και νίκη φιλοξενούμενου.

Η έξοδος του δικτύου περνάει από Softmax ώστε να μετατραπεί σε κατανομή πιθανοτήτων. Κατά την εκπαίδευση χρησιμοποιήθηκε ως συνάρτηση κόστους η CrossEntropyLoss και χρησιμοποιήθηκε και class weights για να αντιμετωπίσει θέματα με το ενδεχόμενο ισοπαλίας γιατί λόγω του μικρού αριθμού αποτελεσμάτων σε σύγκριση των άλλων δύο είναι αρκετά άνισο οπότε βοήθαι στην αντιμετώπιση του προβλήματος, ενώ η βελτιστοποίηση έγινε με τον αλγόριθμο Adam. Τα δεδομένα εκπαιδεύονται σε epochs, και στο τέλος κάθε epoch αξιολογείται η απόδοση του μοντέλου σε σύνολο επικύρωσης μετρώντας accuracy, F1 score και άλλες μετρικές..

```
class FootballPredictor(nn.Module):
    def __init__(self, input_size):
        super().__init__()
        self.net = nn.Sequential(
            nn.Linear(input_size, 128),
            nn.ReLU(),
            nn.Dropout(0.2),
            nn.Linear(128, 64),
            nn.ReLU(),
            nn.Dropout(0.2),
            nn.Linear(64, 32),
            nn.ReLU(),
            nn.Linear(32, 3),
            nn.Softmax(dim=1)
        )

    def forward(self, x):
        return self.net(x)
```

Σχήμα 7.2: Ο κώδικας MLP

7.4.2 Εκπαίδευση με Random Forest

Ένα από τα διάφορα μοντέλα μηχανικής μάθησης που επιτεύχθηκαν ήταν και αυτός του Random Forest. Σε αντίθεση με το MLP χρησιμοποιήθηκε έτοιμη συνάρτηση και συγκεκριμένα το RandomForestClassifier από την βιβλιοθήκη scikit-learn. Οι παράμετροι που χρησιμοποιήθηκαν είναι τα παρακάτω:

- `n_estimators=200`: Αριθμός δέντρων απόφασης στο δάσος.
- `max_depth=10`: Μέγιστο βάθος κάθε δέντρου.
- `min_samples_split=5` και `min_samples_leaf=2`: Περιορισμοί στο ‘σπάσιμο’ των κόμβων και όριο φύλλων, για μεγαλύτερη σταθερότητα και αποφυγή overfitting.
- `max_features='sqrt'`: Τυχαία επιλογή τετραγωνικής ρίζας του πλήθους των χαρακτηριστικών κατά το κάθε split, για μείωση συσχέτισης μεταξύ των δέντρων.
- `class_weight='balanced'`: Αυτόματη προσαρμογή των βαρών των κλάσεων για την αντιμετώπιση της ανισορροπίας μεταξύ των τριών πιθανών αποτελεσμάτων (Νίκη Γηπεδούχου, Ισοπαλία, Νίκη Φιλοξενούμενου).
- `random_state=42` και `n_jobs=-1`: Ορισμός τυχαίου seed για αναπαραγωγικότητα και χρήση όλων των διαθέσιμων επεξεργαστών για παράλληλη εκπαίδευση.

```
self.model = RandomForestClassifier(  
    n_estimators=200,  
    max_depth=10,  
    min_samples_split=5,  
    min_samples_leaf=2,  
    max_features='sqrt',  
    class_weight=class_weights,  
    random_state=42,  
    n_jobs=-1  
)
```

Σχήμα 7.3: Ο κώδικας Random Forest

7.4.3 Εκπαίδευση με XGBoost

Ένα άλλο μοντέλο μηχανικής μάθησης που χρησιμοποιήθηκε είναι το XGBoost το οποίο επίσης υπάρχει έτοιμη συνάρτηση XGBClassifier από την βιβλιοθήκη ξγβοοστ. Για παραμέτρους χρησιμοποιήθηκαν τα παρακάτω.

- `objective='multi:softprob'`: χρησιμοποιείται για πολυκατηγορική πρόβλεψη με πιθανότητες.
- `num_class=3`: δηλώνει τρεις κατηγορίες (Νίκη Γηπεδούχου, Ισοπαλία, Νίκη Φιλοξενούμενου).
- `n_estimators=200, max_depth=5, learning_rate=0.1`: χρησιμοποιούνται για έλεγχο του overfitting και για γρήγορη σύγκλιση του μοντέλου.
- Χρήση `scale_pos_weight` για την αντιμετώπιση της ανισοκατανομής των τάξεων (class imbalance), με υπολογισμό των class weights από τα δεδομένα.

```
self.model = XGBClassifier(  
    objective='multi:softprob',  
    num_class=3,  
    n_estimators=200,  
    max_depth=5,  
    learning_rate=0.1,  
    subsample=0.8,  
    colsample_bytree=0.8,  
    reg_alpha=0.1,  
    reg_lambda=0.1,  
    scale_pos_weight=weights[0]/weights[1],  
    random_state=42  
)
```

Σχήμα 7.4: Ο κώδικας XGBoost

7.4.4 Εκπαίδευση με Logistic Regression

Χρησιμοποιήθηκε επίσης το Logistic Regression που και αυτό επίσης δημιουργήθηκε με έτοιμη συνάρτηση LogisticRegression της βιβλιοθήκης scikit-learn. Για παραμέτρους χρησιμοποιήθηκαν τα παρακάτω:

- `multi_class='multinomial'`: Χρησιμοποιείται η πολυωνυμική (softmax) λογιστική παλινδρόμηση για προβλήματα με περισσότερες από δύο κλάσεις (π.χ. Νίκη Γηπεδούχου, Ισοπαλία, Νίκη Φιλοξενούμενου).
- `solver='lbfgs'`: Επιλέγεται ο βελτιστοποιητής L-BFGS (Limited-memory Broyden-Fletcher-Goldfarb-Shanno), ο οποίος είναι κατάλληλος για πολυωνυμική παλινδρόμηση και μεγάλα σύνολα δεδομένων.
- `max_iter=1000`: Ορίζεται το μέγιστο πλήθος επαναλήψεων στο 1000, ώστε να διασφαλιστεί η σύγκλιση του αλγορίθμου ακόμη και σε πιο δύσκολες περιπτώσεις.
- `class_weight=class_weights`: Εφαρμόζεται εξισορρόπηση των κλάσεων μέσω μεταβλητής `class_weights`, ώστε να αντιμετωπιστεί το πρόβλημα ανισορροπίας στο πλήθος των παραδειγμάτων ανά κλάση.
- `random_state=42`: Ορίζεται συγκεκριμένο (random seed) για επαναληψιμότητα των αποτελεσμάτων.

```
self.model = LogisticRegression(  
    multi_class='multinomial',  
    solver='lbfgs',  
    max_iter=1000,  
    class_weight=class_weights,  
    random_state=42  
)
```

Σχήμα 7.5: Ο κώδικας Logistic Regression

7.4.5 Εκπαίδευση με LightGBM

Το τελευταίο μοντέλο που χρησιμοποιήθηκε είναι το LightGBM που και αυτό επίσης δημιουργήθηκε με έτοιμη συνάρτηση, την βιβλιοθήκη lightgbm. Δημιουργείται η δομή που προτιμά το μοντέλο με βάση των στοιχείων που έγινε η εκπαίδευση και τα υπάρχοντα features. Στην συνέχεια χρησιμοποιήθηκαν παράμετροι που είναι οι παρακάτω:

- `objective='multiclass'`: Επιλέται η συνάρτηση απώλειας για την βελτιστοποίηση στην εκπαίδευση η ταξινόμηση multiclass,

- `num_class=3`: Επιλέγεται ο αριθμός των κλάσεων (νίκη γηπεδούχου, ισοπαλία, νίκη φιλοξενούμενου)
- `metric='multi_logloss'`: Ορίζεται η συνάρτηση κόστους που στην συγκεκριμένη περίπτωση είναι το `multi_logloss`.
- `cboosting_type= 'gbdt'`: Χρησιμοποιείται για boosting αλγόριθμος το Gradient Boosting Decision Trees.
- `num_leaves=31`: Ορίζεται ο μέγιστος αριθμών φύλλων.
- `learning_rate=0,05`: Ορίζεται ο ρυθμός μάθησης που είναι στην προκειμένη περίπτωση 0,05.
- `feature_fraction=0.9`: Ορίζεται το ποσοστό χαρακτηριστικών που επιλέγονται τυχαία σε κάθε επανάληψη. Η τυχαία επιλογή ενός υποσυνόλου χαρακτηριστικών βοηθά στη βελτίωση της ποικιλομορφίας του μοντέλου και στη μείωση του overfitting
- `bagging_fraction=0.8`: Επιλέγεται το ποσοστό των δειγμάτων που χρησιμοποιούνται ανά iteration.
- `bagging_freq=31`: Ορίζεται ο αριθμός που γίνεται bagging.
- `lambda_l1=0.1`: Ορίζεται ο αριθμός την κανονικοποίησης L1.
- `lambda_l2=0.1`: Ορίζεται ο αριθμός την κανονικοποίησης L2.
- `verbose=-1`: Ορίζεται η καταστολή εξόδου logs.

Στο συγκεκριμένο μοντέλο έχει προστεθεί και `early stopping` όπως και `log_evaluation` για την αποφυγή του overfitting.

```
params = {
    'objective': 'multiclass',
    'num_class': 3,
    'metric': 'multi_logloss',
    'boosting_type': 'gbdt',
    'num_leaves': 31,
    'learning_rate': 0.05,
    'feature_fraction': 0.9,
    'bagging_fraction': 0.8,
    'bagging_freq': 5,
    'verbose': -1,
    'lambda_l1': 0.1,
    'lambda_l2': 0.1
}

self.model = lgb.train(
    params,
    train_data,
    num_boost_round=200,
    valid_sets=[lgb.Dataset(X_test, y_test)],
    callbacks=[
        lgb.early_stopping(stopping_rounds=20),
        lgb.log_evaluation(period=20)
    ]
)
```

Σχήμα 7.6: Ο κώδικας LightGBM

7.5 Πρόβλεψη αποτελέσματος

Η διαδικασία πρόβλεψης υλοποιείται αφού έχει προηγηθεί η εξαγωγή και κανονικοποίηση των χαρακτηριστικών (features) και η εκπαίδευση του μοντέλου. Ο χρήστης επιλέγει μέσω του GUI τις δύο ομάδες ενός αγώνα και το σύστημα επιστρέφει τις πιθανότητες για κάθε πιθανή έκβαση: νίκη γηπεδούχου, ισοπαλία ή νίκη φιλοξενούμενου. Τα features συγκεντρώνονται σε ένα αριθμητικό διάνυσμα εισόδου, κανονικοποιούνται με τον ίδιο scaler που χρησιμοποιήθηκε κατά την εκπαίδευση, και περνούν στο εκπαιδευμένο μοντέλο. Το αποτέλεσμα είναι ένα τριπλό διάνυσμα πιθανοτήτων που αντιστοιχεί στα τρία πιθανά αποτελέσματα του αγώνα.


Κεφάλαιο 8

Αποτελέσματα

Σε αυτό το κεφάλαιο παρουσιάζονται τα αποτελέσματα που προέκυψαν από την εκπαίδευση και αξιολόγηση των μοντέλων πρόβλεψης αγώνων χρησιμοποιώντας μετρήσεις όπως accuracy, classification report, confusion matrix.

8.1 Αποτελέσματα MLP

Στο MLP τα αποτελέσματα που βγαίνουν είναι τα εξής



Σχήμα 8.1: Το confusion matrix του MLP.

MLP Evaluation:
Accuracy: 0.59

	precision	recall	f1-score	support
0	0.68	0.60	0.64	329
1	0.48	0.53	0.50	180
2	0.58	0.62	0.60	251
accuracy			0.59	760
macro avg	0.58	0.58	0.58	760
weighted avg	0.60	0.59	0.59	760

Σχήμα 8.2: Το classification report του MLP.

Με βάση τις παρακάτω εικόνες παρατηρείται μεγάλος αριθμός στην νίκη γηπεδούχου που είναι και λογικό εφού υπάρχει πλεονέκτημα έδρας που έχει ψυχολογική επιρροή για τις ομάδες. Επίσης παρατηρείται πολύ μικρός αριθμός ισοπαλιών που επίσης είναι λογικό γιατί και στο database που χρησιμοποιήθηκε αλλά και γενικά είναι το λιγότερο δημοφιλές αποτέλεσμα και αν δεν υπήρχε ισορροπία των labels θα ήταν ακόμα μικρότερος ο αριθμός που θα επηρέαζε και αρνητικά και την απόδοση. Επίσης παρατηρείται απόδοση 0.59 που είναι μια ιδανική απόδοση και φυσικά το σύστημα έχει μάθει τα δεδομένα που χρησιμοποιήθηκαν και δεν επιλέγει τυχαία (θα γινόταν αυτό αν ήταν 0.33). Επίσης παρακάτω υπάρχουν τρεις εικόνες από το GUI που η πρώτη δείχνει ένα μεγάλο πλεονέκτημα της γηπεδούχου απο την αντίπαλο, στην δεύτερη ένα ματς δύο δυνατών ομάδων που συνήθως βγαίνει ισοπαλία και τρίτη φωτογραφία ένα ματς μεσαίας δυναμικότητας ομάδων που είναι κάπως ισάζιες.

Home Team:

Arsenal

Away Team:

Luton Town

Predict

Model ready for predictions


Prediction for Arsenal vs Luton Town:

Home Win: 100.0%

Draw: 0.0%

Away Win: 0.0%

Σχήμα 8.3: Αποτέλεσμα της Arsenal (δυνατής ομάδας) απέναντι στην Luton Town (αδύναμης ομάδας).



Home Team: Manchester City


Away Team: Liverpool

Predict

Model ready for predictions

Prediction for Manchester City vs Liverpool:
Home Win: 0.0%
Draw: 100.0%
Away Win: 0.0%

Σχήμα 8.4: Αποτέλεσμα απέναντι σε δύο δυνατές ομάδες.



Home Team: Brighton and Hove Alb

Away Team: Brentford

Predict

Model ready for predictions


Prediction for Brighton and Hove Albion vs Brentford:
Home Win: 0.1%
Draw: 99.9%
Away Win: 0.0%

Σχήμα 8.5: Αποτέλεσμα απέναντι σε δύο ομάδες ίδιου βελινεκούς.

Όπως παρατηρείται από τις παραπάνω εικόνες το MLP κάνει πιο "σίγουρες" προβλέψεις. Αυτό μπορεί να οφείλεται τόσο στον τρόπο εκπαίδευσης με χρήση της cross-entropy loss, όσο και στη χρήση της συνάρτησης softmax, η οποία ενισχύει τη διαφοροποίηση μεταξύ κατηγοριών.

8.2 Αποτελέσματα Random Forest

Στο Random Forest τα αποτελέσματα που βγαίνουν είναι τα εξής



Σχήμα 8.6: Το confusion matrix του Random Forest.

```

Random Forest Evaluation:
Accuracy: 0.58

```

	precision	recall	f1-score	support
0	0.65	0.63	0.64	329
1	0.43	0.46	0.44	180
2	0.60	0.59	0.60	251
accuracy			0.58	760
macro avg	0.56	0.56	0.56	760
weighted avg	0.58	0.58	0.58	760

Σχήμα 8.7: Το classification report του Random Forest.

Όπως παρατηρούμε το random forest έχει και αυτό θέμα με την ισοπαλία ακόμα μεγαλύτερη από ότι το mlp νωρίτερα που είναι ο ίδιος λόγος που δεν είναι και τόσο αποδοτικό ούτε εκεί. Είναι λιγότερος αποδοτικός από τον MLP αλλά όχι σε μεγάλο βαθμό σε σημείο να μην έχει εκπαιδευτεί το μοντέλο. Παρακάτω θα εμφανιστούν τα αποτελέσματα για τις τρεις περιπτώσεις που έγιναν και στο κομμάτι του MLP με αποτελέσματα από το GUI.

Home Team: Arsenal

Away Team: Luton Town

Predict

Model ready for predictions

Prediction for Arsenal vs Luton Town:
Home Win: 91.8%
Draw: 4.9%
Away Win: 3.3%

Σχήμα 8.8: Αποτέλεσμα της Arsenal (δυνατής ομάδας) απέναντι στην Luton Town (αδύναμης ομάδας).

Home Team: Manchester City

Away Team: Liverpool

Predict

Model ready for predictions

Prediction for Manchester City vs Liverpool:
Home Win: 18.9%
Draw: 80.0%
Away Win: 1.2%

Σχήμα 8.9: Αποτέλεσμα απέναντι σε δύο δυνατές ομάδες.

Home Team: Brighton and Hove Alb

Away Team: Brentford

Predict

Model ready for predictions


Prediction for Brighton and Hove Albion vs Brentford:
Home Win: 27.4%
Draw: 63.1%
Away Win: 9.5%

Σχήμα 8.10: Αποτέλεσμα απέναντι σε δύο ομάδες ίδιου βελινεχούς.

Με βάσει τα αποτελέσματα του GUI παρατηρείται ότι υπάρχουν ίδιες προβλέψεις με του MLP στο κομμάτι του πιο επικρατέστερου αποτελέσματος αλλά δεν είναι τόσο "σίγουρο". Επίσης έστω και για λίγο ποσοστό εμφανίζει ένα πλεονέκτημα στον γηπεδούχο που είναι και κάπως λογικό.

8.3 Αποτελέσματα XGBoost

Στο XGBoost τα αποτελέσματα που βγαίνουν είναι τα εξής:



Σχήμα 8.11: Το confusion matrix του XGBoost.

XGBoost Evaluation:				
Accuracy: 0.58				
	precision	recall	f1-score	support
0	0.61	0.72	0.66	329
1	0.50	0.34	0.40	180
2	0.57	0.57	0.57	251
accuracy			0.58	760
macro avg	0.56	0.54	0.54	760
weighted avg	0.57	0.58	0.57	760

Σχήμα 8.12: Το classification report του XGBoost .

Το συσχεκρισμένο μοντέλο όπως παρατηρείται απο το confusion matrix έχει το πιο έντονο πρόβλημα σε σχέση με τα υπόλοιπα γιατί προβλέπει τα λιγότερα σωστά και έχει μια μεγάλη τάση να προβλέπει νίκες γηπεδούχου. Ο λόγος φυσικά δεν διαφέρει απο τις άλλες περιπτώσεις μοντέλων που όλοι αντιμετωπίζουν το θέμα της ισοπαλίας. Παρακάτω θα σταλθούν τρία παραδείγματα απο το GUI.

Home Team: Arsenal

Away Team: Luton Town

Predict

Model ready for predictions


Prediction for Arsenal vs Luton Town:

Home Win: 99.5%

Draw: 0.3%

Away Win: 0.1%

Σχήμα 8.13: Αποτέλεσμα της Arsenal (δυνατής ομάδας) απέναντι στην Luton Town (αδύναμης ομάδας).



Home Team: Manchester City


Away Team: Liverpool

Predict

Model ready for predictions

Prediction for Manchester City vs Liverpool:
Home Win: 28.3%
Draw: 69.5%
Away Win: 2.2%

Σχήμα 8.14: Αποτέλεσμα απέναντι σε δύο δυνατές ομάδες.



Home Team: Brighton and Hove Alb

Away Team: Brentford

Predict

Model ready for predictions


Prediction for Brighton and Hove Albion vs Brentford:
Home Win: 33.0%
Draw: 56.3%
Away Win: 10.7%

Σχήμα 8.15: Αποτέλεσμα απέναντι σε δύο ομάδες ίδιου βελινεκούς.

Στα παρακάτω αποτελέσματα παρατηρείται η σιγουριά στον γηπεδούχο ενώ στα αποτελέσματα για να γίνουν ισόπαλα είναι πιο οριακές οι μετρικές με μεγάλο ποσοστό προς τον γηπεδούχο.

8.4 Αποτελέσματα Logistic Regression

Στο Logistic Regression τα αποτελέσματα που βγαίνουν είναι τα εξής:



Σχήμα 8.16: Το confusion matrix του Logistic Regression.

```


Model Evaluation:
Accuracy: 0.60

```

	precision	recall	f1-score	support
0	0.67	0.61	0.64	329
1	0.49	0.55	0.52	180
2	0.60	0.61	0.60	251
accuracy			0.60	760
macro avg	0.59	0.59	0.59	760
weighted avg	0.60	0.60	0.60	760

Σχήμα 8.17: Το classification report του Logistic Regression.

Είναι το καλύτερο τόσο σε βάση απόδοσης που είναι 0.6 αλλά τόσο και στην ισορροπία των τιμών. Είναι λογικό όπως αναφέρθηκε και νωρίτερα να υπάρξουν θέματα με την ισοπαλία αλλά είναι το μόνο που έχει τόσο καλό ποσοστό πρόβλεψης. Παρακάτω υπάρχουν παραδείγματα από το GUI.



Home Team: Arsenal

Away Team: Luton Town

Predict

Model ready for predictions


Prediction for Arsenal vs Luton Town:

Home Win: 89.1%

Draw: 5.9%

Away Win: 5.0%

Σχήμα 8.18: Αποτέλεσμα της Arsenal (δυνατής ομάδας) απέναντι στην Luton Town (αδύναμης ομάδας).



Home Team: Manchester City

Away Team: Liverpool

Predict

Model ready for predictions


Prediction for Manchester City vs Liverpool:

Home Win: 13.4%

Draw: 69.3%

Away Win: 17.3%

Σχήμα 8.19: Αποτέλεσμα απέναντι σε δύο δυνατές ομάδες.



Home Team: Brighton and Hove Albion

Away Team: Brentford

Predict

Model ready for predictions

Prediction for Brighton and Hove Albion vs Brentford:

Home Win: 28.7%

Draw: 49.2%


Away Win: 22.0%

Σχήμα 8.20: Αποτέλεσμα απέναντι σε δύο ομάδες ίδιου βελινεκούς.

Σε σύγκριση με τα υπόλοιπα υπάρχει περισσότερη ισορροπία δηλαδή στο πρώτο ματς ενώ είναι σίγουρο ότι η γηπεδούχος είναι το μεγάλο φαβορί υπάρχει περισσότερη αμφιβολία σε σχέση με τα άλλα μοντέλα. Επίσης όπως παρατηρείται δεν υπάρχει το πλεονέκτημα γηπεδούχου και αυτό το κρίνουμε στην δεύτερη φωτογραφία που δίνει πέρα από την ισοπαλία ένα μικρό προβάδισμα στον φιλοξενούμενο.

8.5 Αποτελέσματα LightGBM

Στο LightGBM τα αποτελέσματα που βγαίνουν είναι τα εξής:



Σχήμα 8.21: Το confusion matrix του LightGBM.

```
LightGBM Evaluation:
Accuracy: 0.59
```

	precision	recall	f1-score	support
0	0.61	0.76	0.67	329
1	0.55	0.33	0.41	180
2	0.56	0.54	0.55	251
accuracy			0.59	760
macro avg	0.57	0.54	0.55	760
weighted avg	0.58	0.59	0.57	760

Σχήμα 8.22: Το classification report του LightGBM.

Παρατηρείται ότι το LightGBM έχει μεγαλύτερη απόδοση από το XGBoost οπότε είναι πιο αποδοτικός αλγόριθμος τύπου Gradient Boosting αν και έχει επίσης το πρόβλημα των ισοπαλιών που κατά κύριο λόγο βρίσκει συνεχώς λανθασμένες τιμές. Παρακάτω είναι κάποια παραδείγματα από το GUI.

Home Team:

Arsenal

Away Team:

Luton Town

Predict

Model ready for predictions


Prediction for Arsenal vs Luton Town:

Home Win: 97.1%

Draw: 1.4%

Away Win: 1.5%

Σχήμα 8.23: Αποτέλεσμα της Arsenal (δυνατής ομάδας) απέναντι στην Luton Town (αδύναμης ομάδας).



Home Team: Manchester City


Away Team: Liverpool

Predict

Model ready for predictions

Prediction for Manchester City vs Liverpool:
Home Win: 29.7%
Draw: 60.7%
Away Win: 9.6%

Σχήμα 8.24: Αποτέλεσμα απέναντι σε δύο δυνατές ομάδες.



Home Team: Brighton and Hove Alb

Away Team: Brentford

Predict

Model ready for predictions

Prediction for Brighton and Hove Albion vs Brentford:
Home Win: 33.9%
Draw: 55.1%
Away Win: 10.9%

Σχήμα 8.25: Αποτέλεσμα απέναντι σε δύο ομάδες ίδιου βελινεκούς.

Με τα αποτελέσματα του GUI σε σύγκριση με το XGBoost είναι λίγοτερο βέβαιο για τα αποτελέσματα του και δίνει ελάχιστες παραπάνω πιθανότητες των άλλων αποτελεσμάτων.

Κεφάλαιο 9

Επίλογος

Στην παρούσα εργασία χρησιμοποιήθηκαν δεδομένα από την πενταετία 2019-2024 που αφορούσαν στοιχεία αγωνιστικής επίδοσης των ομάδων εκείνης της περιόδου. Χρησιμοποιήθηκαν πέντε μοντέλα το ένα νευρωνικού δικτύου και τα υπόλοιπα μηχανικής μάθησης. Κάνοντας μια ανάλυση αποτελεσμάτων υπήρξαν κάποια συμπεράσματα.

9.1 Συμπεράσματα

Παρατηρείται έντονη υπεροχή των προβλέψεων υπέρ της γηπεδούχου ομάδας και στα πέντε μοντέλα, κάτι που είναι αναμενόμενο λόγω της φύσης του συνόλου δεδομένων. Επιπλέον, εντοπίζεται κοινό πρόβλημα στην πρόβλεψη της ισοπαλίας, καθώς αποτελεί την πιο δύσκολη κατηγορία για όλα τα μοντέλα. Από τα μοντέλα που δοκιμάστηκαν, η Logistic Regression πέτυχε την υψηλότερη ακρίβεια (0.60), παρουσιάζοντας ταυτόχρονα την πιο ισορροπημένη κατανομή στις προβλέψεις της. Το MLP παρήγαγε πιο ‘σίγουρες’ προβλέψεις, με υψηλές πιθανότητες στην κατηγορία που εμπιστευόταν περισσότερο, γεγονός που φανερώνει αυξημένη αυτοπεποίθηση στις εκτιμήσεις του. Το Random Forest παρουσίασε ικανοποιητική απόδοση, όμως εμφάνισε τάση υπέρ της νίκης του γηπεδούχου, γεγονός που αναδεικνύει το πρόβλημα της μη ισοκατανομής των κατηγοριών στο σύνολο δεδομένων. Όσον αφορά τα μοντέλα Gradient Boosting, το LightGBM εμφάνισε ελαφρώς καλύτερη απόδοση (0.59) σε σύγκριση με το XGBoost (0.58). Και τα δύο, ωστόσο, παρουσιάζουν σημαντική αδυναμία στην πρόβλεψη ισοπαλίας, καθώς σε μεγάλο ποσοστό αποτυγχάνουν να την εντοπίσουν σωστά.

9.2 Ιδέες για μελλοντικές επεκτάσεις

Υπάρχουν πολλές ιδέες που θα μπορούσαν να γίνουν στο μέλλον κομμάτια διπλωματικών εργασιών σε σχέση με την πρόβλεψη αποτελεσμάτων ποδοσφαιρικών αγώνων. Μερικές ιδέες είναι οι παρακάτω:

- Χρήση Real-time data για την πρόβλεψη αποτελεσμάτων έτσι ώστε να είναι πιο έγκυρα τα αποτελέσματα.

- Χρήση στατιστικά παιχτών με κάποιο δείκτη σημαντικότητα (πχ average match rating) και γενικότερα η χρήση παιχτών θα βοηθούσε στην πιο έγκυρη πρόβλεψη.
- Χρησιμοποίηση πιο αντικειμενικών δεδομένων όπως xThreats που ουσιαστικά είναι ο μέσος όρος απειλής της εστίας ανα αγώνα. Είναι αρκετά σημαντική μετρική ώστε να είναι πιο αυθεντικά τα αποτελέσματα.
- Χρήση άλλων μοντέλων νευρωνικών δικτύων θα ήταν καλή δοκιμή ώστε να ελεγχθεί πόσο μπορεί να ανταπεξέλθει σε δεδομένα ποδοσφαιρικών αγώνων.
- Δοκιμή σε άλλα πρωταθλήματα και θα ήταν καλύτερο να υπήρχαν όλα τα ματς εκείνων των ομάδων (π.χ. εθνικό κύπελλο, ευρωπαϊκές διοργανώσεις) ώστε να είναι πιο ακριβής η αγωνιστική φόρμα κάθε ομάδας.

Βιβλιογραφία

- [1] F. Pedregosa *et al.*, “Scikit-learn: Machine Learning in Python,” Available: <https://scikit-learn.org/>. [2011].
- [2] A. Paszke *et al.*, “PyTorch: An Imperative Style, High-Performance Deep Learning Library,” Available: <https://pytorch.org>. [2019].
- [3] T. Chen and C. Guestrin, “XGBoost: A Scalable Tree Boosting System,” Available: <https://xgboost.readthedocs.io/>. [2016].
- [4] GeeksforGeeks, “Neural Networks – A Beginner’s Guide,” Available: <https://www.geeksforgeeks.org/machine-learning/neural-networks-a-beginners-guide/>. [2025].
- [5] GeeksforGeeks, “Multi-layer Perceptron Learning in TensorFlow,” Available: <https://www.geeksforgeeks.org/deep-learning/multi-layer-perceptron-learning-in-tensorflow/>. [2025].
- [6] GeeksforGeeks, “The Role of Softmax in Neural Networks,” Available: <https://www.geeksforgeeks.org/deep-learning/the-role-of-softmax-in-neural-networks-detailed-explanation-and-applications/>. [2025].
- [7] GeeksforGeeks, “Getting Started with PyTorch,” Available: <https://www.geeksforgeeks.org/deep-learning/getting-started-with-pytorch/>. [2025].
- [8] GeeksforGeeks, “Python GUI – Tkinter,” Available: <https://www.geeksforgeeks.org/python/python-gui-tkinter/>. [2025].
- [9] GeeksforGeeks, “Introduction to Matplotlib,” Available: <https://www.geeksforgeeks.org/python-introduction-matplotlib/>. [2025].
- [10] GeeksforGeeks, “Confusion Matrix in Machine Learning,” Available: <https://www.geeksforgeeks.org/confusion-matrix-machine-learning/>. [2025].
- [11] GeeksforGeeks, “NumPy – Python Library,” Available: <https://www.geeksforgeeks.org/numpy/python-numpy/>. [2025].

- [12] GeeksforGeeks, “Backpropagation in Neural Network,” Available: <https://www.geeksforgeeks.org/machine-learning/backpropagation-in-neural-network/>. [2025].
- [13] GeeksforGeeks, “Getting Started with Classification,” Available: <https://www.geeksforgeeks.org/machine-learning/getting-started-with-classification/>. [2025].
- [14] GeeksforGeeks, “Introduction to PySpark and Apache Spark,” Available: <https://www.geeksforgeeks.org/data-science/introduction-pyspark-distributed-computing-apache-spark/>. [2025].
- [15] GeeksforGeeks, “Random Forest Classifier using scikit-learn,” Available: <https://www.geeksforgeeks.org/random-forest-classifier-using-scikit-learn/>. [2025].
- [16] GeeksforGeeks, “LightGBM – Light Gradient Boosting Machine,” Available: <https://www.geeksforgeeks.org/machine-learning/lightgbm-light-gradient-boosting-machine/>. [2025].
- [17] GeeksforGeeks, “functools Module in Python,” Available: <https://www.geeksforgeeks.org/python/functools-module-in-python/>. [2025].
- [18] GeeksforGeeks, “Queue in Python,” Available: <https://www.geeksforgeeks.org/python/queue-in-python/>. [2025].
- [19] GeeksforGeeks, “Introduction to XGBoost,” Available: <https://www.geeksforgeeks.org/machine-learning/xgboost/>. [2025].
- [20] GeeksforGeeks, “Cross Entropy Loss Function,” Available: <https://www.geeksforgeeks.org/machine-learning/what-is-cross-entropy-loss-function/>. [2025].
- [21] GeeksforGeeks, “Understanding Logistic Regression,” Available: <https://www.geeksforgeeks.org/machine-learning/understanding-logistic-regression/>. [2025].
- [22] GeeksforGeeks, “Dropout in Neural Networks,” Available: <https://www.geeksforgeeks.org/machine-learning/dropout-in-neural-networks/>. [2025].
- [23] GeeksforGeeks, “Adam Optimizer,” Available: <https://www.geekforgeeks.org/deep-learning/adam-optimizer/>. [2025].
- [24] GeeksforGeeks, “Underfitting and Overfitting in ML,” [Online]. Available: <https://www.geeksforgeeks.org/machine-learning/underfitting-and-overfitting-in-machine-learning/>. [2025].

- [25] GeeksforGeeks, “Model Building with Scikit-learn,” Available: <https://www.geeksforgeeks.org/learning-model-building-scikit-learn-python-machine-learning-library/>. [2025].
- [26] GeeksforGeeks, “ReLU Activation Function in Deep Learning,”. Available: <https://www.geeksforgeeks.org/deep-learning/relu-activation-function-in-deep-learning/>. [2025].
- [27] DataCamp, “Random Forest Classifier in Python,” Available: <https://www.datacamp.com/tutorial/random-forests-classifier-python>. [2025].
- [28] DataCamp, “Multilayer Perceptrons in Machine Learning,” Available: <https://www.datacamp.com/tutorial/multilayer-perceptrons-in-machine-learning>. [2025].
- [29] PyTorch, “PyTorch with Examples,” Available: https://docs.pytorch.org/tutorials/beginner/pytorch_with_examples.html. [2025].
- [30] Machine Learning Mastery, “Building MLP Models in PyTorch,” Available: <https://machinelearningmastery.com/building-multilayer-perceptron-models-in-pytorch/>. [2025].
- [31] EITCA Academy, “What is Regression in Machine Learning,” [Online]. Available: <https://el.eitca.org/artificial-intelligence/eitc-ai-mlp-machine-learning-with-python/regression/introduction-to-regression/>. [2025].
- [32] Kaggle, “Premier League Matches Dataset,” Available: <https://www.kaggle.com/datasets/sajkazmi/premier-league-matches>. [2025].
- [33] IBM, “What is regularization?,” Available: <https://www.ibm.com/think/topics/regularization>. [2025].
- [34] H2O, “What is Forward Propagation in Neural Networks?,” Available: <https://h2o.ai/wiki/forward-propagation/>. [2025].
- [35] Big Blue Data Academy, “Τι είναι το Machine Learning; Οδηγός για Αρχάριους 2023,” Available: <https://bigblue.academy/gr/ti-einai-to-machine-learning>. [2023].
- [36] SAP, “What is machine learning” Available: <https://www.sap.com/greece/products/artificial-intelligence/what-is-machine-learning.html>. [2023].
- [37] GeeksforGeeks, “Machine Learning Lifecycle,” Available: <https://www.geeksforgeeks.org/machine-learning/machine-learning-lifecycle/>. [2025].
- [38] DeepAI, “Understanding Hidden Layers in Neural Networks,” Available: <https://deepai.org/machine-learning-glossary-and-terms/hidden-layer-machine-learning>. [2025].

- [39] PyTorch, “CrossEntropyLoss,” Available: <https://docs.pytorch.org/docs/stable/generated/torch.nn.CrossEntropyLoss.html>. [2025].
- [40] Medium, “Building a Simple MLP from Scratch Using PyTorch” Available: <https://medium.com/@mn05052002/building-a-simple-mlp-from-scratch-using-pytorch-7d50ca66512b>. [2025].
- [41] GLAZERadr, Github, “Multi Layer Perceptron Using Pytorch” Available: <https://github.com/GLAZERadr/Multi-Layer-Perceptron-Pytorch>. [2023]
- [42] Wikipedia, “Feedforward neural network” Available: https://en.wikipedia.org/wiki/Feedforward_neural_network.
- [43] Wikipedia, “Neural network (machine learning)” Available: [https://en.wikipedia.org/wiki/Neural_network_\(machine_learning\)](https://en.wikipedia.org/wiki/Neural_network_(machine_learning)).
- [44] IBM, “What is classification in machine learning?” Available: <https://www.ibm.com/think/topics/classification-machine-learning>. [2024]
- [45] GeeksforGeeks, “Random Forest Classifier using Scikit-learn” Available: <https://www.geeksforgeeks.org/random-forest-classifier-using-scikit-learn/>. [2025]
- [46] Spiceworks, “What Is Logistic Regression? Equation, Assumptions, Types, and Best Practices” Available: <https://www.spiceworks.com/tech/artificial-intelligence/articles/what-is-logistic-regression/>. [2022]
- [47] Αλέξανδρος Ανδρέου, “Πρόβλεψη Αποτελέσματος Ποδοσφαιρικού Αγώνα”. [2019]
- [48] Ρατσιάλης Γεώργιος, “ΠΡΟΒΛΕΨΗ ΑΠΟΤΕΛΕΣΜΑΤΟΣ ΕΛΛΗΝΙΚΩΝ ΑΓΩΝΩΝ ΜΕ ΤΗΝ ΒΟΗΘΕΙΑ ΜΗΧΑΝΙΚΗΣ ΜΑΘΗΣΗΣ”. [2024]
- [49] Πανάικας Σωτήριος, “Εφαρμογή Τεχνητών Νευρωνικών Δικτύων για την πρόβλεψη αποτελεσμάτων και στατιστικών στο (ελληνικό) Ποδόσφαιρο”. [2024]
- [50] Ενρίκ Μαζάι, “Πρόβλεψη έκβασης αγώνων ποδοσφαίρου με αλγόριθμους μηχανικής μάθησης”. [2024]
- [51] Μανούκος Μάριος, “ΠΡΟΒΛΕΨΗ ΑΠΟΤΕΛΕΣΜΑΤΩΝ ΠΟΔΟΣΦΑΙΡΙΚΩΝ ΑΓΩΝΩΝ ΜΕ ΤΕΧΝΙΚΕΣ ΜΗΧΑΝΙΚΗΣ ΜΑΘΗΣΗΣ”. [2015]
- [52] Καραγεωργός Αργύρης, “Πρόβλεψη αποτελεσμάτων ποδοσφαιρικών αγώνων με χρήση μηχανικής μάθησης”. [2022].

